Hợp nhất đa mô thức trên đồ thị tri thức: Nghiên cứu và tái lập AdaMF-MAT và MKG-FENN cho dự đoán tương tác thuốc

Lê Quốc Hưng [1,2] và Nguyễn Thị Hoàng Nhi [1,2]
[1] Trường Đại học Khoa học tự nhiên, ĐHQG-HCM, Việt Nam
[2] Đại học Quốc gia Thành phố Hồ Chí Minh, Việt Nam
MSHV: 25C11005, 25C01015

***Tóm tắt nội dung*: Báo cáo nghiên cứu và tái lập hai công trình về đồ thị tri thức đa mô thức, loại đồ thị mà mỗi thực thể vừa có quan hệ cấu trúc, vừa kèm mô thức bổ trợ như ảnh và văn bản. *Thách thức.* Các mô thức thường *mất cân bằng và thiếu hụt*, khiến việc hợp nhất chúng để hoàn thiện đồ thị, tức dự đoán liên kết còn thiếu, hay để dự đoán tương tác thuốc–thuốc với nhiều lớp sự kiện, dễ bị mô thức nhiễu chi phối. *Giải pháp.* Hai bài đưa ra hai hướng. AdaMF-MAT công bố tại LREC-COLING 2024 hợp nhất đặc trưng *thích nghi* rồi *huấn luyện đối kháng theo mô thức*, viết tắt là MAT, để cân bằng đóng góp các mô thức; MKG-FENN công bố tại AAAI 2024 hợp nhất *bốn* đồ thị tri thức bằng mạng đầu-cuối cho dự đoán tương tác thuốc. *Cơ chế.* AdaMF-MAT dùng attention gán trọng số cho ba mô thức rồi sinh mẫu đối kháng để tăng cường mô thức yếu; MKG-FENN dùng bốn nhánh GNN kiểu KGNN và một tầng hợp nhất để phân loại 65 loại sự kiện tương tác. *Kết quả của nhóm.* Chúng tôi chạy 40 thí nghiệm công khai trên Weights & Biases và rút ra ba điều. Thứ nhất, đóng góp của MAT *không tái lập được* trên cả ba tập dữ liệu MKG-W, MKG-Y và DB15K, đường cơ sở không MAT của nhóm còn vượt chính số AdaMF-MAT mà bài báo công bố, kể cả ở DB15K nơi bài báo khai MAT mạnh nhất tới $+2{,}63$ MRR. Thứ hai, hợp nhất thích nghi trên thực tế gần như loại bỏ mô thức ảnh. Thứ ba, MKG-FENN *tái lập được* cả ba kịch bản gồm biết thuốc và hai mức cold-start, trong khi bỏ một trong bốn đồ thị không làm giảm độ chính xác ở kịch bản dễ. Đọc mã còn cho thấy MKG-FENN chọn epoch theo tập test, làm F1 lạc quan khoảng 3 đến 4 điểm, cùng nhiều điểm lệch giữa mô tả và mã nguồn ở cả hai công trình.**

***Từ khóa*: đồ thị tri thức đa mô thức, hoàn thiện đồ thị tri thức, hợp nhất thích nghi, huấn luyện đối kháng, dự đoán tương tác thuốc, tái lập nghiên cứu.**

I. Giới thiệu

Đồ thị tri thức (knowledge graph, KG) biểu diễn tri thức dưới dạng bộ ba (h, r, t): thực thể đầu, quan hệ, thực thể đuôi. Khi mỗi thực thể còn được gắn thêm thông tin phi cấu trúc như hình ảnh hay văn bản mô tả, ta có đồ thị tri thức *đa mô thức* (multimodal KG, MMKG). Câu hỏi trung tâm của báo cáo là: làm sao *hợp nhất* các nguồn thông tin không đồng nhất này một cách hiệu quả, khi lượng tín hiệu mỗi mô thức mang lại rất chênh lệch nhau?

Chúng tôi khảo sát hai câu trả lời độc lập cho câu hỏi đó, tương ứng với hai bài báo nhóm đã đăng ký:

- **Phần A: AdaMF-MAT** [1] (bài trình bày seminar). Giải bài toán *hoàn thiện* MMKG (multi-modal KG completion): suy ra các bộ ba còn thiếu. Đề xuất hai thành phần: hợp nhất thích nghi có trọng số học được cho từng mô thức, và một pha đối kháng (MAT) sinh mô thức giả để tăng cường. Với công trình này nhóm *chạy lại thực nghiệm* của tác giả để lấy điểm cộng, nên báo cáo đi sâu vào kết quả tái lập và phân tích phê phán.
- **Phần B: MKG-FENN** [2] (bài được phân công báo cáo). Giải bài toán *dự đoán sự kiện tương tác thuốc–thuốc* (drug–drug interaction, DDI event prediction): với một cặp thuốc, phân loại chúng vào 1 trong 65 loại sự kiện tương tác. Đề xuất xây bốn đồ thị tri thức từ bốn nguồn quan hệ khác nhau của thuốc và hợp nhất chúng đầu-cuối (end-to-end). Dù chỉ được yêu cầu báo cáo, nhóm cũng *chạy lại* cả ba kịch bản (biết thuốc và hai mức cold-start) cùng ablation và phân tích độ nhạy để lấy điểm cộng.

Điểm chung của hai bài là cùng dựa trên ý tưởng "nhiều nguồn tri thức, hợp nhất có học". Điểm khác biệt then chốt: AdaMF-MAT hợp nhất các *mô thức* (cấu trúc/ảnh/văn bản) của cùng một thực thể; MKG-FENN hợp nhất các *loại quan hệ* (hóa học/cấu trúc con/DDI/thuộc tính phân tử) của cùng một thuốc. Đặt cạnh nhau, chúng cho một góc nhìn đối chiếu tốt về "hợp nhất trên đồ thị".

Về phần đóng góp, nhóm trình bày lại cơ chế của cả hai mô hình theo cách hiểu của mình, làm rõ từng thành phần công thức thay vì dán công thức trần; tái lập AdaMF-MAT trên MKG-W bằng chính mã và siêu tham số của tác giả, quét trọn lưới λ rồi báo cáo số đo thật; và chỉ ra các điểm không nhất quán giữa bài báo với mã nguồn ở cả hai công trình, dựa trên việc đọc mã từng dòng và kiểm chứng bằng probe. Toàn bộ log thực nghiệm được ghi nhận công khai, liên kết đặt tại Mục IV và Phụ lục A.

PHẦN A: AdaMF-MAT

II. Bài toán và động lực

A. Hoàn thiện đồ thị tri thức đa mô thức

Cho MMKG chưa đầy đủ, tác vụ là dự đoán thực thể đuôi t đúng cho một truy vấn $(h, r, ?)$. Cách đánh giá chuẩn (*link prediction*, filtered setting): với mỗi bộ ba đúng trong tập kiểm tra, mô hình xếp hạng thực thể đúng giữa toàn bộ thực thể ứng viên; chất lượng đo bằng MRR (mean reciprocal rank) và Hits@k ($k \in \{1, 3, 10\}$). Càng thực thể đúng được xếp gần đầu, điểm càng cao.

Lấy một ví dụ cụ thể. Với truy vấn `(Eiffel Tower, locatedIn, ?)`, mô hình nhận ba mô thức của "Eiffel Tower" (cấu trúc đồ thị, ảnh tháp, mô tả văn bản), hợp nhất chúng thành một embedding chung, rồi để RotatE xoay theo quan hệ `locatedIn` và chấm điểm mọi ứng viên; kết quả mong đợi là `Paris` đứng hạng 1. Nếu ảnh hoặc văn bản bị thiếu, embedding lệch đi và mô hình dễ xếp sai, chẳng hạn đẩy `Rome` lên đầu. Chính tình huống này là động lực của AdaMF-MAT.

B. Vấn đề nghiên cứu: mô thức mất cân bằng

Ngay tên bài báo, *"Unleashing the Power of Imbalanced Modality Information"*, đã nêu thẳng vấn đề: ba mô thức (cấu trúc đồ thị, ảnh, văn bản) đóng góp lượng tín hiệu rất khác nhau, và còn khác nhau tùy từng quan hệ. Có hai cách hợp nhất dễ hỏng. Thứ nhất là lấy trung bình cộng cứng nhắc, coi mọi mô thức quan trọng như nhau. Thứ hai là để một mô thức yếu, thường là ảnh, mang nhiễu và kéo tụt biểu diễn chung. AdaMF-MAT nhắm đúng hai điểm này: hợp nhất thích nghi xử lý cái thứ nhất, còn huấn luyện đối kháng theo mô thức xử lý cái thứ hai.

C. Công trình liên quan (chọn lọc)

Các hướng hợp nhất đa mô thức cho KGC khác nhau ở *cách* gộp mô thức và *gap* chúng vá. IKRL/TBKGC nối hoặc cộng đặc trưng các mô thức: đơn giản nhưng bỏ qua chênh lệch phân phối giữa những không gian mô thức không đồng nhất. RSME thêm cổng (gate) lọc ảnh nhiễu. **OTKGE** coi hợp nhất như bài toán *vận tải tối ưu* (optimal transport) để căn phân phối các mô thức thay vì gộp thô. Nhánh đối kháng (KBGAN, MMRNS) sinh negative khó nhằm tăng chất lượng embedding. AdaMF-MAT đứng ở giao của hai nhánh cuối: hợp nhất bằng *trọng số học được* (thay cổng cứng hay OT) cộng một pha *đối kháng theo mô thức* (thay đối kháng ở mức negative). Đây là bối cảnh để đọc hai đóng góp ở phần sau.

III. Phương pháp AdaMF-MAT

Mô hình xương sống là RotatE [3]: mỗi quan hệ được xem như một phép *quay* trong không gian phức. Với embedding phức của đầu $\mathbf{h}$, quan hệ $\mathbf{r}$ (pha xoay), đuôi $\mathbf{t}$, điểm số một bộ ba là

$$\text{score}(h, r, t) = \gamma - \|\mathbf{h} \circ \mathbf{r} - \mathbf{t}\|, \tag{1}$$

với $\circ$ là nhân phức phần tử, γ là biên (margin, $\gamma = 12$). Bộ ba đúng cho điểm cao, bộ ba sai cho điểm thấp.

Vì sao lại là RotatE mà không phải một KGE khác? Khi coi mỗi quan hệ là phép quay trên vòng tròn đơn vị phức, RotatE suy luận được đồng thời cả bốn mẫu quan hệ: đối xứng, phản đối xứng, nghịch đảo và hợp thành. Các lựa chọn phổ biến đều thiếu một mảnh nào đó, TransE không biểu diễn được đối xứng, DistMult không biểu diễn được phản đối xứng, ComplEx yếu ở hợp thành, nên RotatE biểu đạt quan hệ mạnh hơn cả. Điều này quan trọng vì một khi phần hợp nhất đa mô thức đã tạo xong embedding thực thể chung, chính scorer quan hệ là chỗ dễ thành nút thắt; RotatE lại sẵn đi kèm cơ chế self-adversarial nói ở dưới. Cần nói thêm cho công bằng: bài báo chọn RotatE làm xương sống nhưng không ablate với KGE nào khác, nên đây là lý do lý thuyết chứ không phải bằng chứng thực nghiệm của chính bài.

Một chi tiết của xương sống đáng dừng lại là self-adversarial negative sampling. Hàm loss không cho mọi bộ ba âm trọng số bằng nhau, mà đánh trọng số theo độ khó dưới dạng logit chuẩn hoá bằng softmax:

$$p(h'_j, r, t'_j) \propto \exp\big(\beta \cdot \text{score}(h'_j, r, t'_j)\big), \tag{2}$$

bộ ba âm điểm cao, tức đang trông giống thật, nhận trọng số lớn hơn. Hệ số β đóng vai nhiệt độ: cho $\beta \to 0$ thì trọng số trải đều, β lớn thì dồn vào âm khó nhất (bài dùng $\beta = 2$). Lý do cần nó khá trực tiếp: càng về sau, đa số âm ngẫu nhiên trở nên quá dễ và gradient gần như bằng 0, nên dồn sức vào âm khó mới giữ được gradient hữu ích và hội tụ tốt hơn. Probe tái lập xác nhận đúng chiều, âm khó nhận trọng số 1.0 còn âm dễ 0.0. Điều đáng chú ý là chính bài báo viết ngược dấu: Eq. 6 định nghĩa $\mathcal{F}$ là *khoảng cách* $\|\mathbf{h} \circ \mathbf{r} - \mathbf{t}\|$, rồi Eq. 8 đặt trọng số $\propto \exp(\beta\mathcal{F})$, tức âm càng xa (càng dễ) càng được ưu tiên. Mã dùng điểm $\gamma - \|\cdot\|$ nên đúng chiều; ai cài lại theo công thức trên giấy sẽ được cơ chế ngược hẳn.

A. Hợp nhất thích nghi (AdaMF)

Mỗi thực thể có ba biểu diễn: cấu trúc $\mathbf{e}_s$ (học trực tiếp), ảnh $\mathbf{e}_v$ và văn bản $\mathbf{e}_t$, chiếu tuyến tính từ đặc trưng tiền huấn luyện về cùng số chiều: ảnh dùng VGG (DB15K) hoặc BEiT (MKG-W, MKG-Y), lấy trung bình nhiều ảnh của một thực thể; văn bản dùng vector [CLS] của Sentence-BERT. Mạng trích đặc trưng đóng băng, nhưng bảng đặc trưng ảnh và văn bản vẫn được tinh chỉnh trong lúc huấn luyện. Trọng số hợp nhất được *học* thay vì cố định:

$$\alpha_m = \text{softmax}\big(\mathbf{w}^\top \tanh(\mathbf{e}_m)\big), \quad m \in \{s, v, t\}, \tag{3}$$

$$\mathbf{e}_{\text{joint}} = \textstyle\sum_m \alpha_m \, \mathbf{e}_m. \tag{4}$$

Trực giác: mô thức nào hữu ích cho thực thể hiện tại thì nhận trọng số α_m lớn. Đây là "adaptive" trong tên mô hình. Lưu ý trọng số chỉ phụ thuộc embedding của *thực thể*, không phụ thuộc quan hệ đang hỏi: cùng một thực thể nhận cùng bộ α dù truy vấn là `locatedIn` hay `hasColor`.

Điểm lệch #1 (mã vs bài báo). Bài báo (Eq. 4) viết mỗi mô thức có một vector trọng số $\mathbf{w}_m$ *riêng*. Đọc mã

(`ent_attn = Linear(2d,1)`) cho thấy chỉ có *một* vector $\mathbf{w}$ dùng chung cho cả ba mô thức, và ký hiệu $\oplus$ trong bài thực chất là tích vô hướng. Bản thân Eq. 4 cũng viết chưa đúng kiểu: lấy exp của một tích từng phần tử cho ra vector chứ không ra trọng số vô hướng; phải đọc mã mới biết ý định là điểm vô hướng $\mathbf{w}^\top \tanh(\mathbf{e}_m)$. Nói cách khác, cơ chế attention model học được đơn giản hơn mô tả trong bài.

B. Huấn luyện đối kháng theo mô thức (MAT)

Đóng góp thứ hai. Một bộ sinh (generator) G, mạng truyền thẳng hai lớp LeakyReLU, nhận đầu vào là $[\mathbf{e}_s; \mathbf{z}]$ với $\mathbf{z} \sim \mathcal{N}(0,1)^{64}$, sinh ra các *mô thức giả* h^*, t^*. Ba biến thể bộ ba giả được tạo: (h^*, r, t), (h, r, t^*), (h^*, r, t^*). Mô hình chính đóng vai bộ phân biệt (discriminator) D:

$$\mathcal{L}_D = \mathcal{L}_{\text{kgc}} + \mu \sum_{s \in S} \text{SigmoidLoss}(s), \tag{5}$$

$$\mathcal{L}_G = \sum_{s \in S} \text{SigmoidLoss}(s^+, s), \tag{6}$$

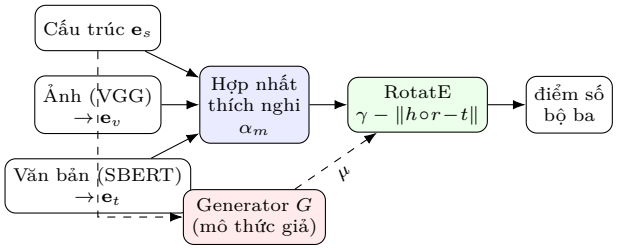
với S là ba bộ ba giả và μ (ký hiệu λ trong bài) là hệ số cân bằng phần đối kháng. Cách ly gradient được xử lý bằng hai optimizer riêng cho D và G: dù $\mathcal{L}_G$ có lan gradient vào tham số D, chỉ `optimizer_g .step()` được gọi rồi `zero_grad()` ở bước D kế tiếp xóa sạch, nên không rò rỉ. Ý tưởng: G ép D học biểu diễn mô thức bền vững hơn trước nhiễu.

Đọc mã còn thấy ba chi tiết bài không nói rõ. Thực thể giả h^* thay *đồng thời* cả ảnh lẫn văn bản và giữ nguyên cấu trúc, nên bộ ba giả chỉ khác bộ ba thật ở hai mô thức bổ trợ. Mã chỉ sinh một nhóm ($L = 1$, tức ba bộ ba giả cho mỗi bộ ba dương), dù Figure 4 của chính bài cho thấy $L = 8$ tốt nhất. Và khi $\mu = 0$, bộ sinh *vẫn* được cập nhật ở mỗi bước, chỉ là loss đối kháng của D bị nhân với 0 nên mô hình chính học y như AdaMF thuần: chi phí tính toán của MAT vẫn phải trả dù MAT không có tác dụng.

Điểm lệch #2 (nghiêm trọng). Cả ba script chính thức (`run_db15k/mkgw/mkgy.sh`) đều đặt `-mu=0`. Theo (5), $\mu = 0$ tắt hoàn toàn phần MAT. Vậy *chạy nguyên bản chỉ tái tạo AdaMF (ablation), không phải AdaMF-MAT.* Bài báo khai đã tìm $\lambda \in \{0{,}1, 0{,}01, 0{,}001\}$ nhưng *không công bố giá trị thắng.* Đây là rào cản tái lập lớn nhất, và là trọng tâm thực nghiệm của nhóm.

C. Minh họa luồng dữ liệu

Hình 1 tóm tắt luồng một bộ ba đi qua mô hình.



Hình 1. Luồng AdaMF-MAT. Ba mô thức được chiếu về cùng không gian, hợp nhất theo trọng số học được α_m, chấm điểm bằng RotatE. Nhánh nét đứt là pha đối kháng MAT, chỉ hoạt động khi $\mu > 0$.

IV. Tái lập thực nghiệm

A. Thiết lập

Mã nguồn: repo chính thức `zjukg/AdaMF-MAT`. Đặc trưng ảnh/văn bản tiền huấn luyện (thiếu trong repo) được tải riêng, kiểm tra khớp chính xác số thực thể trong `entity2id.txt` (Bảng I). Chạy trên GPU NVIDIA Tesla T4 (16GB). Mã nguồn tái lập của nhóm và hướng dẫn chạy lại: https://github.com/lqhung93/graphML-midterm-project.

Bảng I
Thống kê ba tập dữ liệu (đã kiểm chứng từ file thật).

Tập	#thực thể	#quan hệ	train	valid	test
DB15K	12842	279	79222	9904	9902
MKG-W	15000	169	34196	4276	4274
MKG-Y	15000	28	21310	2665	2663

Bẫy tái lập đã gặp. (1) Phải *build lại* `Base.so` (loader C++ của OpenKE) bằng `bash mmkgc/make.sh`; bản dựng sẵn dùng `-march=native` trên máy tác giả có thể ném *Illegal instruction* trên CPU khác kiến trúc. (2) MKG-W/MKG-Y phải truyền `-img_dim=383` (mặc định 4096 cho DB15K), quên sẽ lỗi lệch shape, dùng sẵn script `run_mkgw.sh`. (3) Mã gốc *không có* cơ chế resume; DB15K một run 1000 epoch tốn ∼35 giờ GPU (đo thật: 112–126 s/epoch trên T4), vượt giới hạn 12 giờ mỗi phiên GPU của nhóm. Nhóm tự thêm cờ `-resume` và cắt thành bốn phiên 250 epoch nối tiếp để chạy đủ (mục IV-E).

Siêu tham số (đọc từ script tác giả, MKG-W): `dim=200, margin=12, batch=1024, neg_num=128, lr=2e-5, epoch=1000`. Lưu ý `lr=2e-5` nằm *ngoài* lưới {1e-3, 1e-4, 1e-5} bài báo khai, và DB15K dùng `dim=250` dù bài báo nói "set to 200".

B. Ghi nhận thực nghiệm (Weights & Biases)

Theo yêu cầu đề bài, mỗi thí nghiệm reproduce được ghi nhận công khai. Toàn bộ huấn luyện chạy trên GPU NVIDIA T4; nhóm lưu lại log huấn luyện gốc (loss theo epoch, kết quả từng fold, lệnh chạy đầy đủ). Lúc chạy, môi trường huấn luyện chưa kết nối được W&B, nên các run W&B được nhóm tạo lại sau khi huấn luyện xong, từ kết quả cuối trong log. Vì vậy mỗi run chỉ có một dòng kết quả, không có đường loss, và thời gian chạy cùng máy hiển thị trên W&B là của bước tổng hợp chứ không phải của bước huấn luyện. Config của mỗi run ghi đủ siêu tham số thật; các run được xếp theo group (`adamf/main`, `adamf/mu`, `adamf/db15k`, `adamf/ablation`, `adamf/attention`, `mkgfenn/task1_main`, `mkgfenn/task2`, `mkgfenn/task3`, `mkgfenn/ablation`, `mkgfenn/sensitivity`). Xem Phụ lục A cho bảng ánh xạ đầy đủ run → liên kết.

- Kết quả chính MKG-W (3 seed): https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-k-t-qu-

Bảng II
KẾT QUẢ TÁI LẬP TRÊN MKG-W (SỐ IN ĐẬM LÀ SỐ ĐO CỦA NHÓM; DÒNG *PAPER* TRÍCH TỪ [1]). Δ SO VỚI $\mu = 0$ CỦA NHÓM.

Cấu hình	MRR	H@1	H@3	H@10	ΔMRR
Paper AdaMF (μ=0)	34,27	27,21	37,86	47,21	
Paper AdaMF-MAT	35,85	29,04	39,01	48,42	+1,58
Nhóm μ=0	35,68	28,98	38,68	48,13	
Nhóm λ=0,001	35,73	29,11	38,58	47,99	+0,06
Nhóm λ=0,01	35,04	28,17	38,08	47,40	−0,64
Nhóm λ=0,1	32,03	25,39	34,91	44,05	−3,65

Bảng III
TÁI LẬP MKG-Y, TRỌN LƯỚI λ (SEED 42; DÒNG *PAPER* TRÍCH TỪ [1]). Δ SO VỚI $\mu = 0$ CỦA NHÓM.

Cấu hình	MRR	H@1	H@3	H@10	ΔMRR
Paper AdaMF (μ=0)	38,06	33,49	40,44	45,48	
Paper AdaMF-MAT	38,57	34,34	40,59	45,76	+0,51
Nhóm μ=0	39,10	34,59	41,23	46,68	
Nhóm λ=0,001	39,10	34,59	41,19	46,60	≈ 0
Nhóm λ=0,01	39,13	34,64	41,25	46,58	+0,03
Nhóm λ=0,1	38,43	33,85	40,67	45,96	−0,67

ch-nh-MKG-W-3-seed---VmlldzoxODE3OTk3Mw
- Lưới hệ số MAT trên MKG-W và MKG-Y: https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-l-i-h-s-MAT-tr-n-MKG-W-v-MKG-Y--VmlldzoxODE3OTk3NA
- DB15K 1000 epoch: https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-DB15K-1000-epoch--VmlldzoxODE3OTk3NQ
- Ablation mô thức và trọng số attention (Figure 5): https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-ablation-m-th-c-v-tr-ng-s-attention--VmlldzoxODE3OTk3Ng
- Thiếu mô thức (Figure 3): https://wandb.ai/K35/gml-adamf-mat/runs/ipdub3kv

C. Kết quả chính: MKG-W, quét trọn lưới λ

Báo cáo W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-k-t-qu-ch-nh-MKG-W-3-seed---VmlldzoxODE3OTk3Mw.

Bảng II đối chiếu số nhóm đo được với số bài báo. Một seed (42), chưa lặp nhiều seed nên các chênh lệch nhỏ cần đọc dè dặt.

Bảng cho thấy mấy điều đáng chú ý. Trước hết, đường cơ sở của nhóm đã vượt đường cơ sở bài báo: AdaMF với $\mu = 0$ đạt 35,68 MRR, cao hơn số AdaMF mà bài báo công bố (34,27) tận +1,41 và chỉ kém hàng AdaMF-MAT của họ (35,85) vỏn vẹn 0,17. Nói cách khác, chỉ riêng AdaMF chạy bằng chính script tác giả với MAT tắt đã gần chạm con số mà bài báo gán cho "AdaMF + MAT".

Trên chính con số đó, MAT không tái lập được đóng góp đã công bố. Quét trọn lưới $\lambda \in \{0{,}1, 0{,}01, 0{,}001\}$ như bài báo nêu, giá trị tốt nhất ($\lambda = 0{,}001$) chỉ thêm +0,06 MRR, nằm trong khoảng nhiễu, trong khi bài báo khai +1,58; hai giá trị còn lại đều làm tệ đi, riêng $\lambda = 0{,}1$ sụt tới −3,65. Đáng nói là λ cực nhạy mà giá trị thắng lại không được công bố: chênh giữa $\lambda = 0{,}001$ và $\lambda = 0{,}1$ lên tới 3,71 MRR, nên người tái lập chọn lệch một bậc là mất nhiều hơn toàn bộ đóng góp bài báo khai.

Để kết luận không chỉ dựa trên một lần chạy, nhóm lặp lại với ba seed (42, 1, 2). Trung bình ± độ lệch chuẩn trên MKG-W là $35{,}74 \pm 0{,}06$ cho AdaMF ($\mu = 0$) và $35{,}80 \pm 0{,}07$ cho AdaMF-MAT ($\lambda = 0{,}001$); đóng góp MAT +0,06 MRR nhỏ hơn hoặc ngang độ lệch chuẩn, tức không phân biệt được với 0. Kết luận "MAT không tái lập đóng góp đã công bố" vì vậy có cơ sở thống kê, không còn là quan sát một lần.

Tập DB15K, nơi bài báo báo cáo MAT mạnh nhất (+2,63), được chạy riêng và cũng cho cùng kết luận (mục IV-E).

D. Mở rộng sang MKG-Y: cùng kết luận

Báo cáo W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-l-i-h-s-MAT-tr-n-MKG-W-v-MKG-Y--VmlldzoxODE3OTk3NA.

Nhóm quét trọn lưới λ trên tập thứ hai MKG-Y (seed 42, Bảng III). Kết quả lặp lại MKG-W: đường cơ sở $\mu = 0$ (39,10 MRR) vượt cả số AdaMF (38,06) lẫn AdaMF-MAT (38,57) mà bài báo công bố; MAT tốt nhất ($\lambda = 0{,}01$) chỉ thêm +0,03 MRR (bài báo khai +0,51), nằm trong nhiễu, còn $\lambda = 0{,}1$ tụt −0,67. Hai tập dữ liệu độc lập cho cùng một kết luận: **đóng góp MAT không tái lập được**.

E. DB15K: tập "khó nhất" cho MAT cũng không tái lập

Báo cáo W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-DB15K-1000-epoch--VmlldzoxODE3OTk3NQ.

DB15K là tập bài báo công bố đóng góp MAT lớn nhất (+2,63 MRR). Mã gốc không có cơ chế resume mà một run 1000 epoch tốn ∼35 giờ, vượt giới hạn 12 giờ mỗi phiên GPU. Nhóm thêm cờ `-resume`/`-resume_out`/`-total_epoch`, cắt thành bốn phiên 250 epoch nối tiếp (chuyển trạng thái qua file resume), chạy đủ 1000 epoch cho cả $\mu = 0$ (không MAT) và $\mu = 0{,}01$ (MAT). Ở đây μ chính là hệ số cân bằng MAT mà các mục trên ký hiệu λ theo bài báo (mã gọi là `mu`); ta dùng lại tên biến của mã cho khớp với log. Kết quả (Bảng IV) **lặp lại đúng mẫu của MKG-W/MKG-Y**: đường cơ sở không MAT của nhóm (35,84) vượt *cả* hàng AdaMF-MAT của bài báo (35,14), còn bật MAT ($\mu = 0{,}01$) lại *tụt* −0,41 thay vì +2,63 như công bố. Chênh giữa đường cơ sở bài báo (32,51) và của nhóm (35,84) là +3,33: phần bài báo quy cho MAT phần lớn là do đường cơ sở của họ bị tinh chỉnh dưới mức.

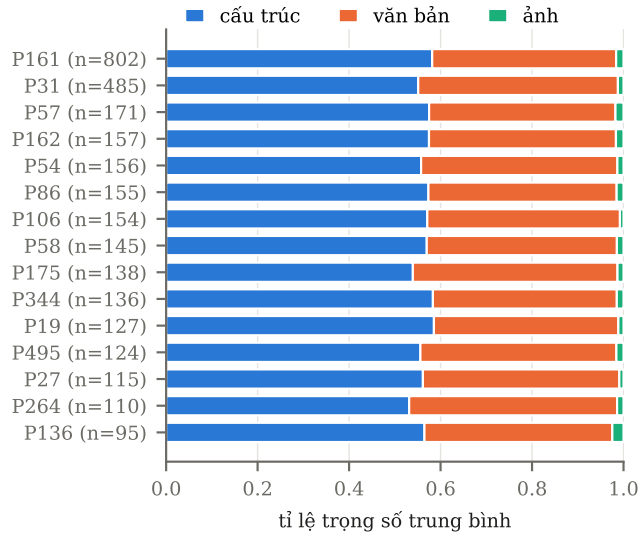
Phạm vi và giới hạn. Cần nói rõ phạm vi của kết luận này. Trên MKG-W và MKG-Y nhóm đã quét *trọn* lưới μ mà bài báo công bố, bao gồm cả giá trị tốt nhất $\mu = 0{,}001$, và đóng góp MAT cao nhất chỉ đạt +0,06. Riêng DB15K, do một run 1000 epoch tốn ∼32 giờ chia bốn phiên, nhóm mới thử được $\mu = 0{,}01$. Vì vậy nhóm *không* tuyên bố đã

Bảng IV
TÁI LẬP DB15K, 1000 EPOCH (SEED 42; DÒNG *PAPER* TRÍCH TỪ [1]). μ LÀ TRỌNG SỐ MAT.

Cấu hình	MRR	H@1	H@3	H@10
Paper AdaMF (μ=0)	32,51	21,31	39,67	51,68
Paper AdaMF-MAT	35,14	25,30	41,11	52,92
Nhóm μ=0 (không MAT)	**35,84**	25,97	41,81	53,63
Nhóm μ=0,01 (MAT)	35,43	25,34	41,50	53,38

Bảng V
TRỌNG SỐ HỢP NHẤT TRUNG BÌNH TRÊN MKG-W (15000 THỰC THỂ, CHECKPOINT $\mu = 0$; TRUNG BÌNH $\pm$ ĐỘ LỆCH CHUẨN TRÊN 3 SEED).

Mô thức	Trọng số trung bình
cấu trúc	$0{,}5658 \pm 0{,}0014$
văn bản	$0{,}4173 \pm 0{,}0015$
ảnh	$\mathbf{0{,}0170 \pm 0{,}0004}$



Hình 2. Trọng số hợp nhất trung bình theo quan hệ (MKG-W, checkpoint $\mu = 0$, seed 42; 15 quan hệ có nhiều bộ ba test nhất, n là số bộ ba). Nhóm vẽ từ checkpoint đã huấn luyện.

bác bỏ MAT trên DB15K ở mọi μ; điều quan sát được là mẫu hành vi của ba tập dữ liệu nhất quán với nhau. Để $\mu = 0{,}001$ trên DB15K đạt +2,63 như công bố thì nó phải tốt hơn hẳn chính $\mu = 0{,}001$ trên hai tập nhóm đã quét kỹ (nơi nó gần như không giúp gì), đồng thời phải cải thiện trên một đường cơ sở mà bản thân đã vượt hàng AdaMF-MAT của bài báo. Đây là khả năng chưa thể loại trừ bằng thực nghiệm, nhưng không được dữ liệu hiện có ủng hộ. Nói gọn, **trên mọi cấu hình nhóm đã thử, xuyên ba tập dữ liệu, MAT không tái lập được mức đóng góp đã công bố**.

V. PHÂN TÍCH PHÊ PHÁN

A. *Trọng số mô thức: hợp nhất thích nghi học cách bỏ ảnh*

Báo cáo W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-ablation-m-th-c-v-tr-ng-s-attention--VmlldzoxODE3OTk3Ng.

Nhóm nạp checkpoint MKG-W ($\mu = 0$) của ba seed (42, 1, 2) và gọi thẳng hàm `get_attention` của model (không xấp xỉ lại). Bảng V là trung bình trên toàn bộ 15000 thực thể; với checkpoint seed 42, nhóm còn tách theo 98 quan hệ trên tập test để so với Figure 5.

Mô hình gần như *vứt bỏ* mô thức ảnh (1,7% trọng số) trong khi văn bản được 41,7%, và thứ tự này giữ nguyên ở cả ba seed. Với một bài mang tên "giải phóng sức mạnh của mô thức mất cân bằng", đây là quan sát đáng nói: cơ chế thích nghi học được cách *bỏ qua* ảnh chứ không phải cân bằng nó.

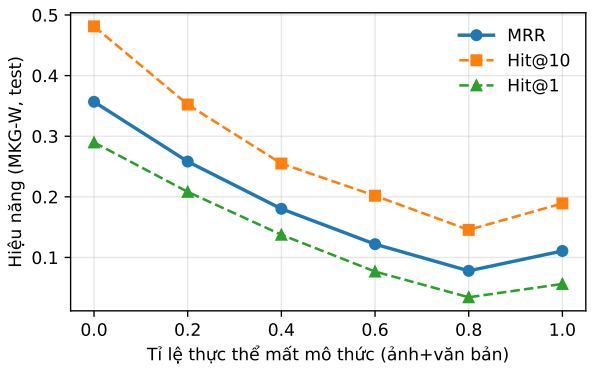
Hình 2 tách trọng số theo quan hệ (15 quan hệ có nhiều bộ ba test nhất, mã thuộc tính Wikidata). Các thanh gần như giống hệt nhau: cấu trúc 0,53 đến 0,59, ảnh không quá 0,03. Điều này khớp với mã: trọng số là của *thực thể*, nên "trọng số theo quan hệ" chỉ là trung bình trên các thực thể xuất hiện trong quan hệ đó, khác nhau chủ yếu do thành phần thực thể chứ không do mô hình thích nghi theo ngữ cảnh. Trên cả 98 quan hệ có trong tập test, thứ tự $s > t > v$ đúng ở 97 quan hệ; quan hệ còn lại chỉ có 2 bộ ba test và ở đó văn bản nhỉnh hơn cấu trúc 0,0014.

Bảng VI
ABLATION MÔ THỨC (MKG-W, $\mu = 0$, SEED 42). Δ SO VỚI FULL.

Cấu hình	MRR	Δ
Full (3 mô thức)	35,68	
Bỏ cấu trúc	34,74	−0,94
Bỏ ảnh	**35,94**	**+0,26**
Bỏ văn bản	34,53	−1,15

Thực nghiệm ablation xác nhận điều này. Khi bỏ từng mô thức khỏi tầng hợp nhất (MKG-W, $\mu = 0$, Bảng VI), bỏ ảnh không những không hại mà còn làm tăng MRR (+0,26), đúng với trọng số 0,017 ở trên: ảnh là mô thức nhiễu, gần như vô ích trên MKG-W. Quan trọng nhất là văn bản (bỏ đi rớt −1,15 MRR), rồi mới đến cấu trúc (−0,94). Table 3 của bài báo làm ablation trên DB15K, còn nhóm làm trên MKG-W (DB15K tốn ∼32 giờ mỗi run), nên hai bảng không so trực tiếp được: bài báo thấy bỏ cấu trúc rớt mạnh nhất, gợi ý thứ tự này phụ thuộc tập dữ liệu. Nhóm cũng chưa chạy hai ablation khác của bài báo (hợp nhất thích nghi so với trung bình, và bỏ từng loại bộ ba tổng hợp của MAT). Mỗi cấu hình một seed; mức +0,26 và −0,94 lớn hơn nhiều độ lệch chuẩn giữa seed của MKG-W (0,06) nên hướng thay đổi đáng tin, còn độ lớn chính xác thì chưa.

Ở đây có một mâu thuẫn nội tại của bài báo. Mục 4.5 viết thứ tự quan trọng thường là $s > v > t$, nhưng chính Figure 5 của họ (cả 7/7 quan hệ) lại cho $s > t > v$ với dải ảnh luôn mỏng nhất. Số nhóm đo trên MKG-W ($s > t > v$ ở 97/98 quan hệ, $s > v > t$ ở 0/98 quan hệ) *khớp với hình* của họ, chỉ lệch với câu văn. (Lưu ý: bài không nói



Hình 3. Độ bền của AdaMF khi thiếu mô thức (MKG-W, checkpoint $\mu = 0$): hiệu năng theo tỉ lệ thực thể bị bỏ ảnh+văn bản. $p = 0$ tái hiện đúng đường cơ sở (MRR 0,3568).

Figure 5 vẽ trên tập nào; nhóm đo trên MKG-W nên phát biểu đúng là "trên MKG-W thứ tự $s > v > t$ không đúng ở bất kỳ quan hệ nào".)

B. Độ bền khi thiếu mô thức (tái lập Figure 3)

Run W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/runs/ipdub3kv.

Figure 3 của bài báo khảo sát độ bền khi một phần thực thể bị thiếu mô thức. Mã nguồn *không* kèm thí nghiệm này, nên nhóm tự viết: nạp checkpoint MKG-W ($\mu = 0$), rồi tại thời điểm kiểm thử, *zero-hóa* đặc trưng ảnh và văn bản cho một tỉ lệ p thực thể chọn ngẫu nhiên (seed 42), đo lại link prediction. Hình 3 là kết quả. Tại $p = 0$, MRR = 0,3568 trùng khớp đường cơ sở của nhóm (kiểm tra checkpoint nạp đúng).

Đường cong này nói hai điều. Thứ nhất, hiệu năng tụt đơn điệu và mạnh khi p tăng từ 0 đến 0,8 (MRR 0,3568 → 0,0779), cho thấy mô hình phụ thuộc thực vào mô thức bổ trợ dù attention gán cho ảnh trọng số rất nhỏ; ảnh không vô dụng mà đóng vai trò khi riêng cấu trúc chưa đủ. Thứ hai, và bất ngờ hơn, tại $p = 1{,}0$ khi mọi thực thể đều thiếu, MRR lại hồi lên 0,1107, cao hơn mức 0,0779 ở $p = 0{,}8$. Lý do là khi tất cả cùng mất mô thức, không gian biểu diễn trở lại nhất quán ở dạng thuần cấu trúc, trong khi thiếu một phần tạo ra hỗn hợp không đồng nhất khó khớp hơn. Đây là một quan sát từ *một* seed và sáu điểm đo (chưa lặp lại nên không kèm thanh sai số), nên chỉ nên xem là *gợi ý*: chính tính không đồng nhất của dữ liệu thiếu có thể gây hại hơn cả lượng thiếu, một góc nhìn mà biểu đồ gốc của bài báo không nêu.

C. Các điểm không nhất quán bài báo ↔ mã nguồn

Tổng hợp từ đọc mã từng dòng và kiểm chứng số:

1) Script chính thức `mu=0` ⇒ chạy nguyên bản không ra AdaMF-MAT; λ thắng không công bố. *(nghiêm trọng)*
2) Eq. 4 nói trọng số riêng từng mô thức; mã dùng *một* vector chung.
3) `dim`: bài báo "200", script DB15K dùng 250.
4) `lr=2e-5` nằm ngoài lưới bài báo khai.
5) Bảng đặc trưng ảnh/văn bản là *khả huấn luyện* (`requires_grad =True`); riêng bảng ảnh DB15K chiếm 52,6M/71,4M tham số, không phải "∼10M".
6) Thí nghiệm modality-missing (Figure 3, RQ2) *không có* trong mã phát hành: `-missing_rate`, `-visual` được khai trong `args.py` nhưng không nơi nào đọc. Muốn tái lập phải tự viết phần bỏ mô thức. *(nghiêm trọng)*
7) Table 1 ghi DB15K valid/test là 9902/9904, file thật đảo ngược 9904/9902, bằng chứng bài báo và artifact không được đối soát.
8) Eq. 8 ngược dấu so với định nghĩa $\mathcal{F}$ là khoảng cách ở Eq. 6; mã đúng chiều.
9) Eq. 12–13 cộng thứ hạng dự đoán đầu và đuôi mà thiếu hệ số 1/2, nên MRR và Hit@K theo công thức có thể vượt 1.
10) Cùng cấu hình AdaMF không MAT trên DB15K, Table 2 ghi 32,51 MRR còn Table 3 ghi 33,19.
11) Mục cài đặt và mã đặt $L = 1$, trong khi Figure 4 cho $L = 8$ tốt nhất.
12) Câu văn Mục 4.5 nói thứ tự $s > v > t$, trái với chính Figure 5 ($s > t > v$).
13) Table 2 đặt chung số baseline trích từ bài MMRNS với số tác giả tự chạy lại, hai nguồn khác cấu hình.

Các phần khớp hoàn toàn: các phương trình RotatE, tập ba bộ ba giả, $K = 128$, $\beta = 2$, $\gamma = 12$, batch 1024, đánh giá filtered.

Tóm lại phần A, đóng góp thứ hai là MAT không tái lập được từ artifact công bố nếu không tự dò lại λ, và hai phương trình lõi (Eq. 4, Eq. 8) mô tả sai chính mã của tác giả. Cái model thực sự học được là *một* vector attention dùng chung, không phải trọng số riêng từng mô thức như bài viết.

D. Đánh giá tổng hợp AdaMF-MAT

Điểm hay. Bài đặt đúng vấn đề: mỗi thực thể có lượng thông tin mô thức khác nhau, nên trọng số hợp nhất phải theo thực thể. Lời giải cho phần này rất rẻ, chỉ một vector attention và một softmax trên ba mô thức, lại cho đường cơ sở mạnh: chạy bằng chính script tác giả, AdaMF đã vượt số AdaMF-MAT mà bài công bố ở cả ba tập. Ý tưởng sinh thẳng embedding mô thức giả bằng một mạng nhỏ, thay vì chọn âm bằng học tăng cường như KBGAN, cũng gọn và dễ huấn luyện.

Điểm dở. Phần đóng góp mới thứ hai, MAT, không đứng vững khi đường cơ sở được chạy đúng. Nhóm thấy ba lý do có thể giải thích (chưa kiểm định riêng từng cái). Một, đường cơ sở trong bài yếu hơn hẳn đường cơ sở chạy lại, nên phần chênh mà bài gán cho MAT có thể chỉ là chênh tinh chỉnh. Hai, bộ sinh chỉ nhìn embedding cấu trúc cộng nhiễu, nên embedding giả mang rất ít thông tin về ảnh và văn bản thật; âm "khó" khi đó là khó giả tạo. Ba, λ cực nhạy (lệch một bậc mất tới 3,7 MRR) mà giá trị thắng không được công bố. Ngoài ra, cái gọi là cân bằng mô thức

Bảng VII
Bốn đồ thị tri thức của MKG-FENN (đọc từ mã).

KG	File	#dòng	#quan hệ	Nội dung
G1	dataset1	6.541	235	thuốc–thực thể hóa học (target/enzyme/...)
G2	dataset2	70.350	1	thuốc–cấu trúc con (chỉ "include")
G3	dataset3	37.264	65	thuốc–thuốc (DDI chính)
G4	dataset4	11.440	13	thuốc–thuộc tính phân tử (MolWt, MolLogP...)

trên thực tế là *bỏ ảnh*, và phần mô tả trên giấy (Eq. 4, Eq. 8, Eq. 12–13) lệch với mã ở chỗ quan trọng.

Rút ra. Một ablation kiểu "tắt thành phần X" chỉ chứng minh được X khi đường cơ sở được tinh chỉnh ngang bằng; nên báo cáo nhiều seed và công bố đúng cấu hình đã dùng. Về hướng mở, nhóm thấy hai việc đáng làm: cho bộ sinh dùng cả mô thức đang có (không chỉ cấu trúc) để embedding giả mang thông tin thật, và cho attention phụ thuộc quan hệ đúng như bài mô tả.

PHẦN B: MKG-FENN

VI. Bài toán dự đoán sự kiện tương tác thuốc

Tương tác thuốc–thuốc (DDI) xảy ra khi dùng đồng thời hai thuốc làm thay đổi hiệu quả hoặc gây tác dụng phụ. MKG-FENN [2] giải bài toán *phân loại đa lớp*: cho một cặp thuốc (A, B), dự đoán *loại sự kiện* tương tác trong 65 loại (`event_num=65`), ví dụ "nguy cơ hoặc mức độ tác dụng phụ tăng lên". Dữ liệu nền gồm 572 thuốc (`n_drug=572`) từ DrugBank, cùng dòng dữ liệu với DDIMDL [5].

Cũng nên hình dung qua một ví dụ. Cho cặp thuốc `(Abemaciclib, Amiodarone)`, mỗi thuốc được tra đặc trưng từ bốn đồ thị tri thức (thực thể hóa học, cấu trúc con, DDI, thuộc tính phân tử) qua bốn nhánh KGNN, ghép thành tám vector rồi đưa qua MLP. Đầu ra là một trong 65 lớp sự kiện, ở đây là "nguy cơ hoặc mức độ tác dụng phụ tăng lên", đúng với nhãn trong `event.db` (dòng `Abemaciclib//Amiodarone//The risk or severity of adverse effects increase`).

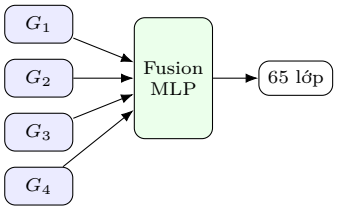
Điểm mấu chốt của bài báo: các phương pháp trước xét quan hệ/cơ chế DDI *rời rạc* (non-end-to-end), nên trích xuất và hợp nhất đặc trưng chưa tối ưu. MKG-FENN xây một đồ thị tri thức đa mô thức từ bốn nguồn quan hệ và học hợp nhất *đầu-cuối* bằng một mạng nơ-ron.

VII. Kiến trúc MKG-FENN

A. Bốn đồ thị tri thức ("đa mô thức")

Bốn đồ thị (Bảng VII), mỗi đồ thị mô tả thuốc theo một góc nhìn quan hệ khác nhau, định dạng `head//tail//relation`.

Nhãn sự kiện lấy từ `event.db` (SQLite), nhãn = cơ chế + hành động, sắp theo tần suất giảm dần thành 65 lớp.



Hình 4. MKG-FENN: bốn nhánh KGNN sinh đặc trưng thuốc theo từng đồ thị; tầng hợp nhất ghép tám vector của cặp thuốc rồi phân loại 65 lớp sự kiện.

B. Bốn nhánh GNN kiểu KGNN

Trái với cái tên "GNN" gợi ý message-passing sâu, mã thực thi là kiểu *lấy mẫu láng giềng + tổng hợp bằng attention* (giống KGNN [4]). Với mỗi đồ thị G_i và mỗi thuốc:

1) **Lấy mẫu.** Chọn ngẫu nhiên K láng giềng ($K = 6$ mặc định) từ G_i (`np.random.choice`, có lặp nếu thiếu), thu tail và quan hệ.
2) **Tính trọng số láng giềng.** Với embedding thuốc, quan hệ, thực thể (số chiều $d = 128$):

$$\mathbf{d}_{\text{rel}} = \mathbf{e}_{\text{drug}} \odot \mathbf{e}_{\text{rel}}, \tag{7}$$

$$\mathbf{s} = \text{ReLU}(\mathbf{d}_{\text{rel}} W_1 + b_1) W_2 + b_2, \tag{8}$$

$$\boldsymbol{\alpha} = \text{softmax}\big(\textstyle\sum \mathbf{s}\big), \tag{9}$$

$$\mathbf{e}_{\text{agg}} = \boldsymbol{\alpha} \cdot \mathbf{e}_{\text{ent}}. \tag{10}$$

3) **Đặc trưng thuốc theo KG.** Ghép $[\mathbf{e}_{\text{agg}}; \mathbf{e}_{\text{drug}}]$ rồi qua Linear $(2d \to d)$+ReLU+BatchNorm, thu $\mathbf{f}_i$.

So với bài báo có hai khác biệt nhỏ nhưng có thật. Eq. 3 của bài là tổng có trọng số không chuẩn hoá, còn mã chuẩn hoá trọng số láng giềng bằng softmax. Bias b_1, b_2 có kích thước $K \times d$, tức gắn với *vị trí* của láng giềng trong lượt lấy mẫu chứ không gắn với láng giềng cụ thể, trong khi các láng giềng được lấy mẫu lại ở mỗi lần forward.

Bẫy chi phí. Ma trận W_1, W_2 có kích thước $572 \times d \times d$, *riêng cho từng thuốc*. Mỗi nhánh vì thế cần $\approx 572 \times 128 \times 128 \times 2 \approx 18{,}7$ triệu tham số, bốn nhánh cộng lại cỡ 75 triệu chỉ cho phần KGNN. Đây là một chi phí tham số đáng kể mà cách mô tả kiến trúc trong bài báo không làm nổi bật, người đọc khó hình dung nếu chỉ nhìn sơ đồ.

C. Tầng hợp nhất (FusionLayer)

Với mỗi cặp (A, B), ghép *tám* vector đặc trưng, $\{\mathbf{f}_1, \ldots, \mathbf{f}_4\}$ của A và của B, thành $8d = 1024$ chiều, rồi qua MLP $1024 \to 512 \to 256 \to 65$ (ReLU+BN+Dropout 0,3), xuất 65 lớp (Hình 4). Khi huấn luyện, mỗi cặp được nhân đôi thành (A, B) và (B, A) để đối xứng hóa.

VIII. Đánh giá và nhận xét

A. Ba kịch bản đánh giá

Mã cung cấp ba tác vụ với độ khó tăng dần:

Bảng VIII
KẾT QUẢ TASK 1 (SỐ BÀI BÁO, TRÍCH TABLE 2 CỦA [2]): MKG-FENN SO VỚI CÁC MÔ HÌNH MẠNH.

Mô hình	ACC	AUPR	AUC	F1	Pre	Rec
MKG-FENN	**0,9409**	**0,9786**	**0,9989**	**0,8958**	**0,9132**	**0,8876**
MDDI-SCL	0,9378	0,9782	0,9983	0,8755	0,8804	0,8767
MDF-SA-DDI	0,9301	0,9737	0,9989	0,8878	0,9085	0,8760
MDNN	0,9175	0,9668	0,9984	0,8301	0,8622	0,8202
DDIMDL	0,8852	0,9208	0,9976	0,7585	0,8471	0,7182

Bảng IX
MKG-FENN TASK 1: NHÓM TÁI LẬP (3 SEED, TRUNG BÌNH ± ĐỘ LỆCH CHUẨN) VS BÀI BÁO.

Chỉ số	Nhóm (3 seed)	Bài báo
ACC	$0{,}9403 \pm 0{,}0012$	0,9409
AUPR (micro)	$0{,}9783 \pm 0{,}0007$	0,9786
AUC (micro)	$0{,}9989 \pm 0{,}0001$	0,9989
F1 (macro)	$0{,}8932 \pm 0{,}0041$	0,8958
Precision (macro)	$0{,}9202 \pm 0{,}0090$	0,9132
Recall (macro)	$0{,}8813 \pm 0{,}0055$	0,8876

- **Task 1**: chia ngẫu nhiên, StratifiedKFold 5-fold trên các cặp DDI. Dễ nhất: cả hai thuốc đều xuất hiện khi huấn luyện.
- **Task 2**: cold-start theo thuốc, kịch bản *một* thuốc trong cặp là mới (chưa xuất hiện khi huấn luyện). Khó hơn Task 1.
- **Task 3**: cold-start khó nhất, *cả hai* thuốc trong cặp đều mới.

Đọc mã cho thấy cold-start được làm như sau, điều bài báo không mô tả. 572 thuốc được chia thành năm nhóm; mỗi lượt một nhóm đóng vai thuốc mới, tập huấn luyện chỉ gồm cặp có cả hai thuốc cũ. Khi đánh giá, embedding của thuốc mới được *thay bằng embedding của thuốc cũ giống nó nhất* theo độ tương đồng Jaccard trên đặc trưng. Nói cách khác, mô hình không suy ra được biểu diễn cho thuốc mới mà mượn biểu diễn của một láng giềng gần nhất. Ngoài ra, mạng của Task 2 và Task 3 chỉ gồm GNN1 đến GNN3 và tầng hợp nhất $3 \cdot 2d$ chiều: cold-start thực tế dùng *ba* đồ thị, không phải bốn như bài viết. Chỉ số: ACC, AUPR, AUC, F1 (micro/macro), Precision, Recall, bộ 11 chỉ số toàn cục theo file supplementary.

B. Kết quả chính (theo bài báo)

Trên kịch bản thuốc đã biết (Task 1, DrugBank v5.1.7, 572 thuốc, 65 sự kiện), bài báo báo cáo MKG-FENN vượt mọi mô hình so sánh ở toàn bộ 6 chỉ số (Bảng VIII, số trích trực tiếp từ Table 2 của bài báo); tổng thắng 64/66 so sánh chỉ số × mô hình (2 hòa, 0 thua), F-rank cao nhất 11,83.

Một điều lộ rõ qua ba kịch bản là cold-start rất khó. Cùng một mô hình, ACC tụt mạnh theo độ khó: 0,9409 ở Task 1 (cả hai thuốc đã thấy), xuống 0,6805 ở Task 2 (một thuốc mới), rồi chỉ còn 0,4552 ở Task 3 (cả hai đều mới). Khoảng cách đó cho thấy phần lớn thành công nằm ở kịch bản dễ, còn dự đoán cho thuốc hoàn toàn mới vẫn là bài toán mở. Ở hai kịch bản cold-start, bài báo cũng không thắng toàn diện: tổng 31 thắng, 5 thua; chẳng hạn ACC Task 3 của MDDI-SCL (0,4589) cao hơn MKG-FENN (0,4552), còn F1 và Precision Task 2 thua MDF-SA-DDI. Còn các giá trị $p = 0{,}0156$ của kiểm định Wilcoxon cần đọc thận trọng: đó là giá trị nhỏ nhất có thể khi so 6 cặp ($1/2^6$, một phía), và 6 cặp ở đây là 6 chỉ số tương quan của *cùng một* lần chạy, không phải nhiều lần chạy độc lập.

Ba yếu tố bài báo coi là quan trọng nhất (phân tích độ nhạy): số láng giềng lấy mẫu tốt nhất = 6, "trọng số mất mát phân loại" (CLW) tốt nhất = 10^{-8}, số chiều embedding = 128. Trong mã, CLW thực chất là `weight_decay` của Adam, tức hệ số điều chuẩn ℓ_2, không phải trọng số của một thành phần loss. Supplementary quét số láng giềng trong $\{4, 5, 6, 7\}$ và cho biết mọi thí nghiệm chạy trên CPU (Windows, i5, 8GB RAM), khớp với việc mã gốc không hỗ trợ GPU. Bài dùng 120 epoch, lr = 0,01, batch 1024: các giá trị này khớp mã (dù nằm ngoài tập `choices` khai trong argparse, nên đây là lỗi khai báo chứ không phải lệch paper↔mã).

C. Nhóm tái lập (GPU T4, 3 seed)

Báo cáo W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/reports/MKG-FENN-Task-1-3-seed--VmlldzoxODE3OTk3Nw. Mã nguồn tái lập: https://github.com/lqhung93/graphML-midterm-project.

Nhóm GPU-hóa mã (thêm `.to(device)`, mã gốc chỉ chạy CPU) và chạy lại Task 1 (120 epoch, 5-fold) với **3 seed** (0, 1, 2), mỗi lần ∼1 giờ. Trung bình ± độ lệch chuẩn **khớp bài báo ở mọi chỉ số, số bài báo nằm trong khoảng ±std** (Bảng IX) ⇒ MKG-FENN *tái lập được*. Đây là tương phản rõ với Phần A, nơi đóng góp MAT của AdaMF-MAT *không* tái lập được: cùng một thái độ kiểm chứng nghiêm túc cho hai kết luận trái ngược, tùy công trình.

Nhóm dùng một tiêu chí tái lập thực dụng xuyên suốt báo cáo: xem là *nhất quán với bài báo* khi con số công bố nằm trong một độ lệch chuẩn mẫu của nhóm qua ba lần chạy độc lập. Đây là kiểm tra khoảng tin cậy, không phải kiểm định giả thuyết hình thức, nên phát biểu đúng là "không phân biệt được với số công bố ở mức nhiễu ba seed", chứ không khẳng định bằng chứng mạnh hơn thế. Theo tiêu chí này, số bài báo nằm trong khoảng ở cả 6 chỉ số. Link W&B (3 seed): https://wandb.ai/K35/gml-adamf-mat/runs/r628r0ym, https://wandb.ai/K35/gml-adamf-mat/runs/o01zi2q5, https://wandb.ai/K35/gml-adamf-mat/runs/3x8y37ey.

D. Nhóm tái lập cold-start (Task 2 và Task 3)

Báo cáo W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/reports/MKG-FENN-cold-start-Task-2-v-Task-3--VmlldzoxODE3OTk3OA.

Nhóm chạy lại luôn kịch bản khó Task 2 (cold-start, một thuốc mới) với **3 lần** độc lập (GPU T4, seed 1, 2, 3, 100 epoch theo mặc định của mã, mỗi lần ∼1 giờ).

Bảng X
MKG-FENN Task 2 (cold-start, một thuốc mới): nhóm tái lập (3 lần, trung bình ± độ lệch chuẩn).

Chỉ số	Nhóm (3 lần)	Bài báo
ACC	$0{,}6772 \pm 0{,}0039$	0,6805
AUPR (micro)	$0{,}7010 \pm 0{,}0015$	–
AUC (micro)	$0{,}9663 \pm 0{,}0008$	–
F1 (macro)	$0{,}5294 \pm 0{,}0045$	–
Precision (macro)	$0{,}5862 \pm 0{,}0075$	–
Recall (macro)	$0{,}5045 \pm 0{,}0071$	–

Bảng XI
MKG-FENN Task 3 (cold-start, cả hai thuốc mới): nhóm tái lập (3 lần, trung bình ± độ lệch chuẩn).

Chỉ số	Nhóm (3 lần)	Bài báo
ACC	$0{,}4598 \pm 0{,}0175$	0,4552
AUPR (micro)	$0{,}4140 \pm 0{,}0165$	–
AUC (micro)	$0{,}9153 \pm 0{,}0014$	–
F1 (macro)	$0{,}2162 \pm 0{,}0076$	–
Precision (macro)	$0{,}2618 \pm 0{,}0092$	–
Recall (macro)	$0{,}2097 \pm 0{,}0107$	–

ACC trung bình $0{,}6772 \pm 0{,}0039$, **số bài báo** 0,6805 **nằm trong khoảng ± độ lệch chuẩn** (Bảng X) ⇒ tái lập được cả ở kịch bản cold-start, không chỉ Task 1 dễ. Lưu ý mã Task 2 chỉ tính AUPR/AUC theo micro và F1/Precision/Recall theo macro (các ô còn lại gán cứng bằng 0, nhóm không ghi các ô này lên W&B), nên AUPR mà bài báo báo ở Table 3/4 thực chất là AUPR micro; cách trung bình macro trên nhiều lớp sự kiện hiếm khiến F1/Precision/Recall thấp hơn hẳn Task 1, phản ánh đúng độ khó của dự đoán cho thuốc chưa từng thấy.

Link W&B (3 lần): https://wandb.ai/K35/gml-adamf-mat/runs/7xspj9x8, https://wandb.ai/K35/gml-adamf-mat/runs/hloy7vw3, https://wandb.ai/K35/gml-adamf-mat/runs/86w5hqon.

Nhóm chạy tiếp **Task 3** (cold-start, *cả hai* thuốc mới: khó nhất), cũng 3 lần (seed 1, 2, 3, 120 epoch; Bảng XI). ACC trung bình $0{,}4598 \pm 0{,}0175$, **số bài báo** 0,4552 **nằm trong ± độ lệch chuẩn** ⇒ tái lập được ở cả ba kịch bản. Chỉ số F1/Precision/ Recall (macro) tụt sâu (∼0,21–0,26) đúng như kỳ vọng khi mọi cặp thuốc đều chưa từng thấy. Nhóm phải tự GPU-hóa mã Task 3 (giống Task 2) vì bản gốc chỉ chạy CPU.

Link W&B (3 lần): https://wandb.ai/K35/gml-adamf-mat/runs/6n59pyvb, https://wandb.ai/K35/gml-adamf-mat/runs/swvbyr32, https://wandb.ai/K35/gml-adamf-mat/runs/wqablhkc. Cả ba kịch bản cold-start đều tái lập được (số bài báo nằm trong 1 độ lệch chuẩn), nghĩa là các con số chính của MKG-FENN *đáng tin*, tương phản với MAT của AdaMF-MAT (Phần A). Đây là nhận định về *tính tái lập*, không phải về giá trị kiến trúc: ngược lại, ablation ở dưới cho thấy tiền đề "cần đủ bốn đồ thị" của chính bài không tái lập được ở Task 1.

Bảng XII
MKG-FENN KG-ablation (Task 1, seed 0): bỏ 1 đồ thị.

Bỏ	Nội dung	ACC	F1 (macro)
(full)	4 đồ thị	0,9389	0,8944
G1	hóa học	0,9409	0,8943
G2	cấu trúc con	0,9399	0,8956
G3	DDI	0,9411	0,9000
G4	phân tử	0,9398	0,8982

E. Ablation KG: bỏ một đồ thị không làm giảm ACC Task 1

Báo cáo W&B của phần này: https://wandb.ai/K35/gml-adamf-mat/reports/MKG-FENN-ablation-th-v-nh-y-si-u-tham-s---VmlldzoxODE3OTk3OQ.

Nhóm bỏ từng đồ thị khỏi FusionLayer (Task 1, seed 0, Bảng XII) bằng cách gán embedding của nhánh đó bằng 0. Kích thước đầu vào MLP giữ nguyên, nhưng các trọng số nhận đầu vào 0 không còn tác dụng, nên tương đương bỏ hẳn nhánh. **Bỏ bất kỳ KG nào, kể cả đồ thị DDI (G3), đều không làm giảm ACC**: cả bốn cấu hình (0,9398 đến 0,9411) nằm trong dải của ba seed mô hình đầy đủ (0,9389 đến 0,9410). Vì mỗi cấu hình chỉ một seed, nhóm không kết luận cấu hình nào tốt hơn full; điều đọc được là *không thấy* mức giảm vượt nhiễu giữa seed. Điều này lệch với Table 5 của bài báo: ở đó cả bốn tổ hợp ba đồ thị chỉ đạt 0,9344 đến 0,9355, thấp hơn full ∼0,6 điểm, tức gấp khoảng năm lần độ lệch chuẩn giữa seed của nhóm (0,0012), xem Hình 5b. Bài báo không nói cách bỏ kênh, nên khác biệt có thể một phần do cách cài đặt. *Phạm vi:* nhóm chỉ chạy bốn cấu hình bỏ một đồ thị trong 15 tổ hợp của Table 5, chỉ trên Task 1; cold-start (Task 2/3) có thể khác.

F. Phân tích độ nhạy siêu tham số (Task 1, seed 0)

Nhóm quét lại hai siêu tham số bài báo nhấn mạnh: số láng giềng lấy mẫu (`neighbor_sample_size`) và số chiều embedding (`embedding_num`), mỗi giá trị một lần (seed 0) trên GPU T4 (Bảng XIII). Với `neighbor_sample_size`, ACC dao động 0,9389 đến 0,9410, đúng bằng dải của ba seed mô hình gốc, nên nhóm không phân biệt được các giá trị với nhau và cũng không xác nhận được "số láng giềng = 6 tốt nhất" như bài báo. Với `embedding_num`, 32 chiều kém rõ (−1,4 điểm, khoảng mười hai lần độ lệch chuẩn giữa seed), nên ảnh hưởng của dung lượng mô hình ở đầu thấp là thật; còn chênh giữa 64, 128 và 256 (tối đa +0,36 điểm) cần thêm seed mới kết luận được, trong khi 256 tốn gấp 2,5 lần thời gian. Nhóm chưa quét tham số thứ ba bài báo nêu là trọng số loss phân loại (CLW).

Sáu run này nằm cùng báo cáo W&B với ablation đồ thị: https://wandb.ai/K35/gml-adamf-mat/reports/MKG-FENN-ablation-th-v-nh-y-si-u-tham-s---VmlldzoxODE3OTk3OQ.

Bảng XIII
MKG-FENN độ nhạy siêu tham số (Task 1, seed 0). ACC = micro.

Siêu tham số	Giá trị	ACC	F1 (macro)
`neighbor_sample_size`	4	0,9409	0,8939
	6 (gốc)	0,9389	0,8944
	10	0,9410	0,8979
	16	0,9390	0,8940
`embedding_num`	32	0,9246	0,8466
	64	0,9384	0,8867
	128 (gốc)	0,9389	0,8944
	256	0,9425	0,8965

Bảng XIV
MKG-FENN: chỉ số ở epoch được chọn theo test so với epoch cuối (nhóm tính từ log; trung bình theo fold rồi trung bình 3 lần chạy, nên hơi khác số gộp ở các bảng trên).

	ACC		F1 (macro)	
Kịch bản	chọn	cuối	chọn	cuối
Task 1	0,9403	0,9420	0,8859	0,8585
Task 2	0,6781	0,6741	0,5432	0,5142
Task 3	0,4670	0,4505	0,2365	0,1959

G. Bẫy tái lập của MKG-FENN

Ngoài số tái lập trên, đọc mã còn lộ vài điểm cần lưu nếu ai muốn tái lập:

1) Repo chỉ có `event.rar`, mã lại cần `event.db`; phải giải nén trước, nếu không `sqlite3.connect` sẽ lỗi.
2) GNN3 hardcode `num_embeddings=67` cho bảng quan hệ trong khi dataset3 chỉ có 65 quan hệ (đệm +2), cần kiểm off-by-two là cố ý hay lỗi.
3) Mặc định `lr=1e-2` và `epoches=120` nằm *ngoài* tập `choices` khai trong argparse, giá trị thật khác lưới liệt kê.
4) Lấy mẫu láng giềng ngẫu nhiên *mỗi lần forward* ⇒ kết quả có phương sai giữa các lần chạy dù đã cố định seed. Nên báo cáo trung bình nhiều lần thay vì một con số.

H. Giao thức đánh giá: chọn epoch theo tập test

Đọc kỹ hàm huấn luyện còn lộ một vấn đề phương pháp quan trọng hơn mọi điểm lệch ở trên. Trong mỗi fold, mã đánh giá trên *tập test* sau từng epoch và giữ lại đầu ra của epoch có macro-F1 trên test cao nhất; không có tập validation riêng. Số báo cáo vì thế là số tốt nhất trên test qua toàn bộ quá trình huấn luyện, tức lạc quan. Vì log huấn luyện ghi chỉ số test sau mỗi epoch, nhóm tính lại được mức lạc quan này mà không cần chạy thêm GPU: so epoch được chọn với epoch cuối cùng (cách làm hợp lệ khi không có validation), Bảng XIV.

Vì tiêu chí chọn là macro-F1, F1 bị đẩy lên rõ nhất: +0,027 ở Task 1, +0,029 ở Task 2 và +0,041 ở Task 3, tức cỡ 20% giá trị F1 của Task 3. ACC Task 1 không tăng, nhưng ACC Task 3 tăng +0,017, gần bằng một độ lệch chuẩn giữa các lần chạy. Hệ quả cho chính phần tái lập của nhóm: "tái lập được" ở các mục trên nghĩa là tái lập *cùng giao thức*; nếu đánh giá đúng cách, các số F1 và số cold-start của MKG-FENN sẽ thấp hơn số công bố.

Một rủi ro khác nằm ở đồ thị G3: nó được dựng từ *toàn bộ* 37.264 sự kiện DDI, gồm cả các cặp thuộc fold test, với quan hệ chính là loại sự kiện, tức nhãn cần dự đoán. Khi lấy mẫu láng giềng, mô hình có thể gặp đúng cặp test cùng nhãn của nó. Xác suất này thấp (6 láng giềng trên khoảng 130 láng giềng trung bình mỗi thuốc), và thí nghiệm bỏ G3 không làm giảm ACC Task 1, nên nhóm cho rằng rò rỉ qua G3 không phải nguồn chính của số Task 1; với cold-start thì nhóm chưa kiểm.

Bảng XV
Đối chiếu hai công trình.

	AdaMF-MAT	MKG-FENN
Tác vụ	hoàn thiện KG (link prediction)	phân loại sự kiện DDI (65 lớp)
Hợp nhất	các *mô thức* (cấu trúc/ảnh/văn bản)	các *loại quan hệ* (4 đồ thị)
Xương sống	RotatE + đối kháng	KGNN 4 nhánh + MLP
Đầu-cuối	có	có
Nhóm chạy lại	có (MKG-W, MKG-Y, DB15K)	có (Task 1/2/3, ablation, quét siêu tham số)

I. Đánh giá tổng hợp MKG-FENN

Điểm hay. Bài nhìn thuốc qua nhiều đồ thị tri thức cùng lúc và học hợp nhất đầu-cuối, một thiết kế dễ hiểu, chạy được cả trên CPU, và số Task 1 tái lập sát bài báo ở cả 6 chỉ số. Việc đánh giá ba mức độ khó, từ thuốc đã biết tới cả hai thuốc mới, cho thấy trung thực rằng cold-start vẫn rất khó.

Điểm dở. Lợi ích của bốn đồ thị chưa được chứng minh thuyết phục: bỏ một đồ thị không làm giảm Task 1, và cold-start, nơi thông tin ngoài nhãn cần nhất, lại chỉ dùng ba đồ thị. Thiết kế W_1, W_2 riêng cho từng thuốc tốn khoảng 75 triệu tham số cho 572 thuốc và không áp được cho thuốc mới, nên cold-start phải mượn embedding của thuốc giống nhất. Giao thức chọn epoch theo test và kiểm định Wilcoxon trên 6 chỉ số làm các khẳng định vượt trội yếu hơn vẻ ngoài của bảng kết quả.

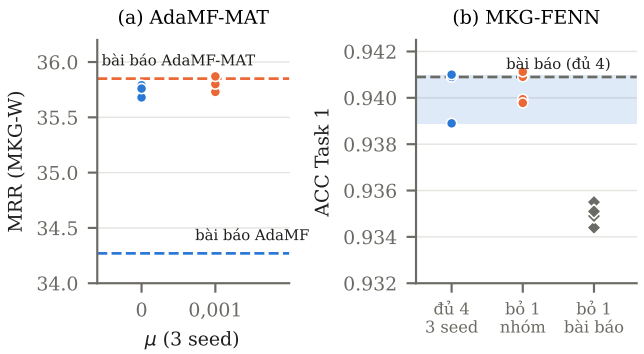
Rút ra. Muốn tin một con số, phải đọc cả mã đánh giá chứ không chỉ mã mô hình. Hướng mở nhóm đề xuất: tách tập validation, dựng G3 chỉ từ cặp huấn luyện, biểu diễn thuốc mới từ đặc trưng của nó thay vì tra bảng, và báo cáo nhiều lần chạy kèm kiểm định giữa các lần chạy.

J. So sánh hai công trình

Bảng XV đặt cạnh hai cách "hợp nhất trên đồ thị".

IX. Bài học khi tái lập

Đặt hai công trình cạnh nhau, nhóm rút ra mấy bài học áp dụng được cho việc đọc bất kỳ bài báo học máy nào.



Hình 5. Độ phân tán giữa các lần chạy của nhóm so với chênh lệch mà bài báo báo cáo. (a) AdaMF-MAT trên MKG-W: 3 seed cho $\mu = 0$ và $\mu = 0{,}001$; nét đứt là số bài báo. (b) MKG-FENN Task 1: dải 3 seed của mô hình đầy đủ (vùng tô), bốn cấu hình bỏ một đồ thị của nhóm, và bốn cấu hình tương ứng trong Table 5 của bài báo (hình thoi). Nhóm vẽ từ số đo trong báo cáo.

Nhiễu giữa các lần chạy phải được đo trước khi so sánh. Hình 5 đặt độ phân tán giữa seed của nhóm cạnh chênh lệch mà bài báo dùng để kết luận. Ở AdaMF-MAT, khoảng cách giữa $\mu = 0$ và $\mu = 0{,}001$ nhỏ hơn cả độ phân tán giữa seed, trong khi bài báo khai +1,58. Ở MKG-FENN, bốn cấu hình bỏ một đồ thị nằm gọn trong dải ba seed của mô hình đầy đủ. Một con số một lần chạy không đủ để nói thành phần nào có ích.

Đường cơ sở quyết định đóng góp. Đóng góp của MAT biến mất khi AdaMF được chạy bằng chính script của tác giả, vì đường cơ sở chạy lại cao hơn hẳn số bài báo ghi cho nó. Muốn chứng minh một thành phần, đường cơ sở phải được tinh chỉnh ngang bằng.

Đọc mã đánh giá, không chỉ mã mô hình. Lỗi có ảnh hưởng lớn nhất nhóm tìm thấy ở MKG-FENN không nằm trong kiến trúc mà trong vòng huấn luyện: chọn epoch theo tập test. Ở AdaMF-MAT, cấu hình quan trọng nhất (μ) nằm trong script chạy chứ không trong bài.

Công thức trên giấy có thể khác mã. Cả hai bài đều có công thức lệch mã ở chỗ then chốt (trọng số attention, dấu của trọng số âm, chuẩn hoá láng giềng, số đồ thị ở cold-start). Khi hai nguồn mâu thuẫn, mã là thứ thực sự tạo ra số.

Ghi lại quá trình ngay từ đầu. Nhóm phải dựng lại sổ thí nghiệm sau khi đã huấn luyện xong vì lúc chạy chưa kết nối được công cụ ghi log; giữ nguyên log gốc là điều giúp nhóm vẫn kiểm chứng được mọi con số, kể cả mức lạc quan ở Bảng XIV.

X. Kết luận

Hai công trình cùng theo đuổi hợp nhất có học trên đồ thị tri thức đa mô thức nhưng cho hai bài học trái ngược về tính tái lập.

Với AdaMF-MAT, nhóm quét trọn lưới hệ số MAT trên *ba* tập dữ liệu (MKG-W có thêm ba seed, MKG-Y, và DB15K chạy đủ 1000 epoch bằng cơ chế resume tự thêm). Trên cả ba, đóng góp cốt lõi thứ hai là MAT không tái lập được mức đã công bố: ở MKG-W chỉ $+0{,}06 \pm 0{,}07$ MRR so với +1,58, và ngay tại DB15K nơi bài báo khai MAT mạnh nhất (+2,63) thì cấu hình đã thử lại *giảm* 0,41, trong khi đường cơ sở không MAT của nhóm còn vượt chính hàng AdaMF-MAT của bài báo. Phần hợp nhất thích nghi hoá ra học cách loại bỏ mô thức ảnh, và thí nghiệm thiếu mô thức mà nhóm tự viết (tái lập Figure 3) còn gợi ý rằng tính không đồng nhất của dữ liệu thiếu gây hại hơn cả lượng thiếu.

Với MKG-FENN, cả ba kịch bản (biết thuốc và hai mức cold-start) đều tái lập trong một độ lệch chuẩn *theo đúng giao thức của mã*. Nhưng giao thức đó chọn epoch theo tập test, làm F1 lạc quan khoảng 3 đến 4 điểm; ablation của nhóm không tái lập được mức giảm khi bỏ một đồ thị mà Table 5 báo cáo; cold-start thực tế chỉ dùng ba đồ thị và mượn embedding của thuốc giống nhất; và kiến trúc tuy gọn về ý tưởng lại nặng về tham số (W_1, W_2 riêng từng thuốc). Cả hai trường hợp củng cố nguyên tắc làm việc của nhóm: không tin một phát biểu trong bài báo cho đến khi chỉ được dòng mã thực thi nó. Hướng tiếp theo nhóm muốn làm là chạy lại các thí nghiệm ablation với nhiều seed và ghi log trong lúc huấn luyện, đánh giá lại MKG-FENN với tập validation riêng, và thử bộ sinh có điều kiện mạnh hơn cho MAT.

Phụ lục A
Ánh xạ thực nghiệm → liên kết Weights & Biases

Toàn bộ **40 run** đều ở chế độ xem công khai trong project https://wandb.ai/K35/gml-adamf-mat. Danh sách đầy đủ liên kết từng thí nghiệm:

AdaMF-MAT, MKG-W (nhiều seed, ablation mô thức, trọng số attention):

- μ=0 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/qxown5dl
- μ=0 seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/k354evcb
- μ=0 seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/9af2psno
- μ=0,001 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/f9cf4x8f
- μ=0,001 seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/zj1788o7
- μ=0,001 seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/1lhysap5
- μ=0,01 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/sc9m0keu
- μ=0,1 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/5w6rka9v
- ablation bỏ cấu trúc: https://wandb.ai/K35/gml-adamf-mat/runs/rilzsiqn
- ablation bỏ ảnh: https://wandb.ai/K35/gml-adamf-mat/runs/cvgimw2j
- ablation bỏ văn bản: https://wandb.ai/K35/gml-adamf-mat/runs/77e9wlty

- trọng số mô thức (Figure 5) seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/cwnekvuv
- trọng số mô thức seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/tj6p6n72
- trọng số mô thức seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/pfk5ok3p
- thiếu mô thức (Figure 3): https://wandb.ai/K35/gml-adamf-mat/runs/ipdub3kv

AdaMF-MAT, MKG-Y (lưới μ):

- μ=0: https://wandb.ai/K35/gml-adamf-mat/runs/64amdvgx
- μ=0,001: https://wandb.ai/K35/gml-adamf-mat/runs/2d6cplzt
- μ=0,01: https://wandb.ai/K35/gml-adamf-mat/runs/85xezi64
- μ=0,1: https://wandb.ai/K35/gml-adamf-mat/runs/5nkdeeui

AdaMF-MAT, DB15K (1000 epoch):

- μ=0 (không MAT): https://wandb.ai/K35/gml-adamf-mat/runs/cjefby6u
- μ=0,01 (MAT): https://wandb.ai/K35/gml-adamf-mat/runs/86ki6d7x

MKG-FENN, Task 1 (3 seed, ablation đồ thị, độ nhạy siêu tham số):

- seed 0: https://wandb.ai/K35/gml-adamf-mat/runs/r628r0ym
- seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/o01zi2q5
- seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/3x8y37ey
- bỏ G1: https://wandb.ai/K35/gml-adamf-mat/runs/yqu4qtwp
- bỏ G2: https://wandb.ai/K35/gml-adamf-mat/runs/yq0wyql5
- bỏ G3: https://wandb.ai/K35/gml-adamf-mat/runs/kcoyhcsv
- bỏ G4: https://wandb.ai/K35/gml-adamf-mat/runs/krxvj5yv
- ns=4: https://wandb.ai/K35/gml-adamf-mat/runs/pnzncirw
- ns=10: https://wandb.ai/K35/gml-adamf-mat/runs/9xktau7r
- ns=16: https://wandb.ai/K35/gml-adamf-mat/runs/mjdlfme6
- emb=32: https://wandb.ai/K35/gml-adamf-mat/runs/nzdee5fy
- emb=64: https://wandb.ai/K35/gml-adamf-mat/runs/2k7kzbbr
- emb=256: https://wandb.ai/K35/gml-adamf-mat/runs/wc3qt7ke

MKG-FENN, cold-start (Task 2 và Task 3):

- Task 2 lần 1: https://wandb.ai/K35/gml-adamf-mat/runs/7xspj9x8
- Task 2 lần 2: https://wandb.ai/K35/gml-adamf-mat/runs/hloy7vw3
- Task 2 lần 3: https://wandb.ai/K35/gml-adamf-mat/runs/86w5hqon
- Task 3 lần 1: https://wandb.ai/K35/gml-adamf-mat/runs/6n59pyvb
- Task 3 lần 2: https://wandb.ai/K35/gml-adamf-mat/runs/swvbyr32
- Task 3 lần 3: https://wandb.ai/K35/gml-adamf-mat/runs/wqablhkc

Tài liệu

[1] Y. Zhang, Z. Chen, L. Liang, H. Chen, and W. Zhang, "Unleashing the Power of Imbalanced Modality Information for Multimodal Knowledge Graph Completion," in *Proc. LREC-COLING*, 2024. arXiv:2402.15444.

[2] D. Wu, W. Sun, Y. He, Z. Chen, and X. Luo, "MKG-FENN: A Multimodal Knowledge Graph Fused End-to-end Neural Network for Accurate Drug–Drug Interaction Prediction," in *Proc. AAAI*, vol. 38, no. 9, 2024, pp. 10216–10224. DOI: 10.1609/aaai.v38i9.28887.

[3] Z. Sun, Z.-H. Deng, J.-Y. Nie, and J. Tang, "RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space," in *Proc. ICLR*, 2019.

[4] X. Lin, Z. Quan, Z.-J. Wang, T. Ma, and X. Zeng, "KGNN: Knowledge Graph Neural Network for Drug–Drug Interaction Prediction," in *Proc. IJCAI*, 2020, pp. 2739–2745.

[5] Y. Deng, X. Xu, Y. Qiu, J. Xia, W. Zhang, and S. Liu, "A multimodal deep learning framework for predicting drug–drug interaction events," *Bioinformatics*, vol. 36, no. 15, pp. 4316–4322, 2020.

[6] X. Han et al., "OpenKE: An Open Toolkit for Knowledge Embedding," in *Proc. EMNLP (System Demonstrations)*, 2018, pp. 139–144.

[7] L. Biewald, "Experiment Tracking with Weights and Biases," 2020. [Online]. Available: https://www.wandb.com/