Hợp nhất thông tin trên đồ thị tri thức: Nghiên cứu và tái lập AdaMF-MAT cho hoàn thiện đồ thị và MKG-FENN cho dự đoán tương tác thuốc

Lê Quốc Hưng [1,2] và Nguyễn Thị Hoàng Nhi [1,2]
[1] Trường Đại học Khoa học tự nhiên, ĐHQG-HCM, Việt Nam
[2] Đại học Quốc gia Thành phố Hồ Chí Minh, Việt Nam
MSHV: 25C11005, 25C01015

***Tóm tắt nội dung*: *Tiêu đề bài báo:* báo cáo nghiên cứu và tái lập hai công trình: "Unleashing the Power of Imbalanced Modality Information for Multi-modal Knowledge Graph Completion" (AdaMF-MAT, LREC-COLING 2024) và "MKG-FENN: A Multi-modal Knowledge Graph Fused End-to-end Neural Network for Accurate Drug–Drug Interaction Prediction" (MKG-FENN, AAAI 2024). *Khái niệm:* đồ thị tri thức đa mô thức, nơi mỗi thực thể có quan hệ cấu trúc kèm mô thức bổ trợ như ảnh, văn bản, dùng cho hoàn thiện đồ thị và dự đoán sự kiện tương tác thuốc. *Thách thức hiện tại:* các mô thức *mất cân bằng và thiếu hụt*, nên phép hợp nhất dễ bị mô thức nhiễu chi phối. *Giải pháp đề xuất:* AdaMF-MAT hợp nhất *thích nghi* rồi *huấn luyện đối kháng theo mô thức* (MAT); MKG-FENN hợp nhất *bốn* đồ thị tri thức trong một mạng end-to-end. *Cơ chế hoạt động:* AdaMF-MAT dùng attention gán trọng số cho ba mô thức và sinh mẫu đối kháng; MKG-FENN dùng bốn nhánh GNN kiểu KGNN và một tầng hợp nhất phân loại 65 loại sự kiện. *Kết quả đạt được:* nhóm chạy lại bằng chính mã và script tác giả công bố, ghi nhận 67 run công khai trên Weights & Biases. Đường cơ sở AdaMF (không MAT) chạy lại đạt hoặc vượt số AdaMF-MAT đã công bố, xác nhận quy trình chạy đúng; trên nền đó, trong phạm vi các cấu hình đã thử, MAT *chưa tái hiện* được mức cải thiện công bố (đo được $+0{,}06$ trên MKG-W và $-0{,}01$ trên MKG-Y qua 3 seed, so với $+1{,}58$ và $+0{,}51$). Trên MKG-W, ảnh chỉ nhận 1,7% trọng số hợp nhất. MKG-FENN tái lập được ở Task 1 trên cả sáu chỉ số; ở cold-start, ACC khớp còn một số chỉ số macro thấp hơn nhẹ; bỏ một đồ thị không làm giảm ACC qua 3 seed, khác mức giảm bài báo công bố. Đọc mã còn cho thấy MKG-FENN chọn epoch theo macro-F1 trên tập test, cùng một số điểm lệch giữa mô tả và mã ở cả hai công trình.**

***Từ khóa*: đồ thị tri thức đa mô thức, hoàn thiện đồ thị tri thức, hợp nhất thích nghi, huấn luyện đối kháng, dự đoán tương tác thuốc, tái lập nghiên cứu.**

I. Giới thiệu

Đồ thị tri thức (knowledge graph, KG) biểu diễn tri thức dưới dạng bộ ba (h, r, t): thực thể đầu, quan hệ, thực thể đuôi. Khi mỗi thực thể còn được gắn thêm thông tin phi cấu trúc như hình ảnh hay văn bản mô tả, ta có đồ thị tri thức *đa mô thức* (multimodal KG, MMKG). Câu hỏi trung tâm của báo cáo là: làm sao *hợp nhất* các nguồn thông tin không đồng nhất này một cách hiệu quả, khi lượng tín hiệu mỗi mô thức mang lại rất chênh lệch nhau?

Chúng tôi khảo sát hai câu trả lời độc lập cho câu hỏi đó, tương ứng với hai bài báo nhóm đã đăng ký:

- **Phần A: AdaMF-MAT** [1] (bài trình bày seminar). Giải bài toán *hoàn thiện* MMKG (multi-modal KG completion): suy ra các bộ ba còn thiếu. Đề xuất hai thành phần: hợp nhất thích nghi có trọng số học được cho từng mô thức, và một pha đối kháng (MAT) sinh mô thức giả để tăng cường. Nhóm cố gắng *chạy lại thực nghiệm* của tác giả để kiểm tra mức độ tái lập của các con số công bố, từ đó hiểu rõ hơn công trình; vì vậy báo cáo đi sâu vào kết quả tái lập và đối chiếu bài báo với mã nguồn.
- **Phần B: MKG-FENN** [2] (bài được phân công báo cáo). Giải bài toán *dự đoán sự kiện tương tác thuốc* (drug–drug interaction, DDI event prediction): với một cặp thuốc, phân loại chúng vào 1 trong 65 loại sự kiện tương tác. Đề xuất xây bốn đồ thị tri thức từ bốn nguồn quan hệ khác nhau của thuốc và hợp nhất chúng theo kiểu end-to-end, tức huấn luyện mọi thành phần cùng lúc trong một mạng. Dù chỉ được yêu cầu báo cáo, nhóm cũng cố gắng *chạy lại* cả ba kịch bản (biết thuốc và hai mức cold-start) cùng ablation và phân tích độ nhạy, để kiểm chứng kết quả bài báo công bố và hiểu rõ hơn mô hình hoạt động tốt ở đâu, kém ở đâu. Phần B là bài chỉ yêu cầu báo cáo; nhóm vẫn đối chiếu bài báo với mã và nêu mọi điểm lệch tìm được như ở Phần A, nhưng không tự thiết kế thêm thí nghiệm ngoài các thí nghiệm của bài.

Điểm chung của hai bài là cùng dựa trên ý tưởng "nhiều nguồn tri thức, hợp nhất có học". Điểm khác biệt then chốt: AdaMF-MAT hợp nhất các *mô thức* (cấu trúc/ảnh/văn bản) của cùng một thực thể; MKG-FENN hợp nhất các *loại quan hệ* (hóa học/cấu trúc con/DDI/thuộc tính phân tử) của cùng một thuốc. Đặt cạnh nhau, chúng cho một góc nhìn đối chiếu tốt về "hợp nhất trên đồ thị".

Việc kiểm chứng này chỉ làm được nhờ cả hai nhóm tác giả đã công bố mã, dữ liệu và script chạy; nhóm coi đó là

điểm cộng lớn của hai công trình. Đóng góp của báo cáo, mỗi mục kèm nơi đặt bằng chứng:

1) Trình bày lại cơ chế hai mô hình theo cách hiểu của nhóm, giải thích từng thành phần công thức (Mục III, VII).
2) Tái lập AdaMF-MAT trên ba tập: trọn lưới hệ số MAT trên MKG-W và MKG-Y (cấu hình chính lặp 3 seed), DB15K 1.000 epoch (Bảng IV đến VI, Hình 2).
3) Phân tích trọng số mô thức, ablation mô thức và độ bền khi thiếu mô thức (Bảng VII, VIII, Hình 4).
4) Tái lập MKG-FENN ở ba kịch bản (3 lần chạy mỗi kịch bản), ablation đồ thị và độ nhạy siêu tham số (Bảng XII đến XIV).
5) Chỉ ra giao thức chọn epoch theo tập test của MKG-FENN và đo mức chênh từ log (Bảng XV).
6) Danh mục điểm lệch giữa bài báo và mã, kèm vị trí mã (Mục V, Phụ lục B).

Toàn bộ log thực nghiệm được ghi nhận công khai, liên kết đặt ở đầu mỗi mục thực nghiệm và ở Phụ lục A. Quy ước: bảng, hình, phương trình của *bài báo gốc* luôn ghi kèm trích dẫn, ví dụ Bảng 2 [1], Hình 3 [1], phương trình 4 [1]; bảng của báo cáo này đánh số La Mã (Bảng I, II,...), hình và phương trình của báo cáo không kèm trích dẫn, phương trình ghi số trong ngoặc như (5). Hệ số cân bằng MAT mà bài gọi là λ được ký hiệu μ theo tên biến trong mã, thống nhất trong mọi bảng và hình.

PHẦN A: AdaMF-MAT

Bảng I tóm tắt cách nhóm hiểu bài báo theo bảy câu hỏi; các mục phía sau đi vào chi tiết và bằng chứng cho từng dòng.

Bảng I
AdaMF-MAT theo khung phân tích của nhóm (chi tiết ở mục ghi trong ngoặc).

Tóm tắt	Hoàn thiện đồ thị tri thức đa mô thức: hợp nhất cấu trúc, ảnh, văn bản bằng trọng số học theo thực thể (AdaMF), thêm bộ sinh embedding mô thức giả làm âm khó (MAT), chấm điểm bằng RotatE (Mục III).
Khoảng trống nghiên cứu	Cách hợp nhất cũ như nhau cho mọi thực thể dù lượng thông tin mô thức chênh lệch; ảnh và văn bản ít, khó trích, hay thiếu; lấy mẫu âm cũ chỉ *chọn* âm có sẵn (Mục II).
Giải pháp	Softmax trên ba mô thức cho mỗi thực thể; bộ sinh hai lớp từ embedding cấu trúc cộng nhiễu tạo ba bộ ba giả; tối ưu min-max với hệ số μ (bài ký hiệu λ) (Mục III).
Kết quả (bài báo)	DB15K, MKG-W, MKG-Y; MRR và Hit@1/3/10 lọc; vượt 19 baseline ở cả ba tập, MRR DB15K 35,14 so với 32,68 của MMRNS (Mục III-D).
Điểm hiệu quả và hạn chế	Đường cơ sở AdaMF chạy bằng script tác giả rất mạnh (vượt AdaMF-MAT công bố trên MKG-Y, DB15K). MAT chưa tái hiện mức công bố (trọn lưới trên MKG-W, MKG-Y; một giá trị μ trên DB15K); trên MKG-W ảnh nhận trọng số rất thấp. Giả thuyết chưa kiểm định: khác cấu hình giữa bài và mã phát hành, bộ sinh thiếu thông tin, μ nhạy mà không công bố (Mục IV, V).
Bài học rút ra	Ablation "tắt thành phần" chỉ có nghĩa khi đường cơ sở tinh chỉnh ngang bằng; công thức trên giấy lệch mã ở chỗ then chốt nên phải đọc mã (Mục V-D).
Hướng mở	Tác giả: kết hợp LLM với đồ thị đa mô thức, kịch bản thiếu mô thức sát thực tế hơn. Nhóm: bộ sinh dùng cả mô thức đang có, attention theo quan hệ, báo cáo nhiều seed (Mục V-D).

II. Bài toán và động lực

A. Hoàn thiện đồ thị tri thức đa mô thức

Cho MMKG chưa đầy đủ, tác vụ là dự đoán thực thể đuôi t đúng cho một truy vấn $(h, r, ?)$. Cách đánh giá chuẩn (*link prediction*, filtered setting): với mỗi bộ ba đúng trong tập kiểm tra, mô hình xếp hạng thực thể đúng giữa toàn bộ thực thể ứng viên; chất lượng đo bằng MRR (mean reciprocal rank) và Hits@k ($k \in \{1, 3, 10\}$). Càng thực thể đúng được xếp gần đầu, điểm càng cao.

Lấy một ví dụ cụ thể. Với truy vấn `(Eiffel Tower, locatedIn, ?)`, mô hình nhận ba mô thức của "Eiffel Tower" (cấu trúc đồ thị, ảnh tháp, mô tả văn bản), hợp nhất chúng thành một embedding chung, rồi để RotatE xoay theo quan hệ `locatedIn` và chấm điểm mọi ứng viên; kết quả mong đợi là `Paris` đứng hạng 1. Nếu ảnh hoặc văn bản bị thiếu, embedding lệch đi và mô hình dễ xếp sai, chẳng hạn đẩy `Rome` lên đầu. Chính tình huống này là động lực của AdaMF-MAT.

B. Vấn đề nghiên cứu: mô thức mất cân bằng

Ngay tên bài báo, *"Unleashing the Power of Imbalanced Modality Information"*, đã nêu thẳng vấn đề: ba mô thức (cấu trúc đồ thị, ảnh, văn bản) đóng góp lượng tín hiệu rất khác nhau, và còn khác nhau tùy từng quan hệ. Có hai cách hợp nhất dễ hỏng. Thứ nhất là lấy trung bình cộng cứng nhắc, coi mọi mô thức quan trọng như nhau. Thứ hai là để một mô thức yếu, thường là ảnh, mang nhiễu và kéo tụt biểu diễn chung. AdaMF-MAT nhắm đúng hai điểm này: hợp nhất thích nghi xử lý cái thứ nhất, còn huấn luyện đối kháng theo mô thức xử lý cái thứ hai.

C. Công trình liên quan (chọn lọc)

Các hướng hợp nhất đa mô thức cho KGC khác nhau ở *cách* gộp mô thức và *khoảng trống* chúng vá. IKRL [11] và TBKGC [12] nối hoặc cộng đặc trưng các mô thức: đơn giản nhưng bỏ qua chênh lệch phân phối giữa những không gian mô thức không đồng nhất. RSME [13] thêm cổng (gate) lọc ảnh nhiễu. **OTKGE** [14] coi hợp nhất như bài toán *vận tải tối ưu* (optimal transport) để căn phân phối các mô thức thay vì gộp thô. Nhánh lấy mẫu âm có học (KBGAN [15], MMRNS [16], MANS [17]) tìm mẫu âm khó nhằm tăng chất lượng embedding. AdaMF-MAT đứng ở giao của hai nhánh cuối: hợp nhất bằng *trọng số học được* (thay cổng cứng hay OT) cộng một pha *đối kháng theo mô thức* (thay đối kháng ở mức negative). Đây là bối cảnh để đọc hai đóng góp ở phần sau.

III. Phương pháp AdaMF-MAT

Mô hình xương sống là RotatE [3]: mỗi quan hệ được xem như một phép *quay* trong không gian phức. Với embedding phức của đầu $\mathbf{h}$, quan hệ $\mathbf{r}$ (pha xoay), đuôi $\mathbf{t}$, điểm số một bộ ba là

$$\text{score}(h, r, t) = \gamma - \|\mathbf{h} \circ \mathbf{r} - \mathbf{t}\|, \tag{1}$$

với $\circ$ là nhân phức phần tử, γ là biên (margin, $\gamma = 12$). Bộ ba đúng cho điểm cao, bộ ba sai cho điểm thấp.

Vì sao lại là RotatE mà không phải một KGE khác? Khi coi mỗi quan hệ là phép quay trên vòng tròn đơn vị phức, RotatE suy luận được đồng thời cả bốn mẫu quan hệ: đối xứng, phản đối xứng, nghịch đảo và hợp thành. Các lựa chọn phổ biến đều thiếu một mảnh nào đó, TransE [8] không biểu diễn được đối xứng, DistMult [9] không biểu diễn được phản đối xứng, ComplEx [10] yếu ở hợp thành, nên RotatE biểu đạt quan hệ mạnh hơn cả. Điều này quan trọng vì một khi phần hợp nhất đa mô thức đã tạo xong embedding thực thể chung, chính scorer quan hệ là chỗ dễ thành nút thắt; RotatE lại sẵn đi kèm cơ chế self-adversarial nói ở dưới. Cần nói thêm cho công bằng: bài báo chọn RotatE làm xương sống nhưng không thử thay bằng KGE nào khác, nên đây là lý do lý thuyết chứ không phải bằng chứng thực nghiệm của chính bài.

Một chi tiết của xương sống đáng dừng lại là lấy mẫu âm tự đối kháng (self-adversarial negative sampling). Hàm loss không cho mọi bộ ba âm trọng số bằng nhau, mà đánh trọng số theo độ khó dưới dạng logit chuẩn hoá bằng softmax:

$$p(h'_j, r, t'_j) \propto \exp\big(\beta \cdot \text{score}(h'_j, r, t'_j)\big), \tag{2}$$

bộ ba âm điểm cao, tức đang trông giống thật, nhận trọng số lớn hơn. Hệ số β đóng vai nhiệt độ: cho $\beta \to 0$ thì trọng số trải đều, β lớn thì dồn vào âm khó nhất (bài dùng $\beta = 2$). Lý do cần nó khá trực tiếp: càng về sau, đa số âm ngẫu nhiên trở nên quá dễ và gradient gần như bằng 0, nên dồn sức vào âm khó mới giữ được gradient hữu ích và hội tụ tốt hơn. Một thí nghiệm kiểm tra nhỏ của nhóm xác nhận mã chạy đúng chiều: âm khó nhận trọng số 1,0 còn âm dễ 0,0. Điều đáng chú ý là công thức trên giấy dường như lệch dấu (nhiều khả năng là lỗi in): phương trình 6 [1] định nghĩa $\mathcal{F}$ là *khoảng cách* $\|\mathbf{h} \circ \mathbf{r} - \mathbf{t}\|$, rồi phương trình 8 [1] đặt trọng số $\propto \exp(\beta\mathcal{F})$, tức âm càng xa (càng dễ) càng được ưu tiên. Mã dùng điểm $\gamma - \|\cdot\|$ nên đúng chiều; ai cài lại theo công thức trên giấy sẽ được cơ chế ngược hẳn.

A. Hợp nhất thích nghi (AdaMF)

Mỗi thực thể có ba biểu diễn: cấu trúc $\mathbf{e}_s$ (học trực tiếp), ảnh $\mathbf{e}_v$ và văn bản $\mathbf{e}_t$, chiếu tuyến tính từ đặc trưng tiền huấn luyện về cùng số chiều: ảnh dùng VGG [18] (DB15K) hoặc BEiT [19] (MKG-W, MKG-Y), lấy trung bình nhiều ảnh của một thực thể; văn bản dùng vector [CLS] của Sentence-BERT [20]. Mạng trích đặc trưng đóng băng, nhưng bảng đặc trưng ảnh và văn bản vẫn được tinh chỉnh trong lúc huấn luyện. Trọng số hợp nhất được *học* thay vì cố định:

$$\alpha_m = \text{softmax}\big(\mathbf{w}^\top \tanh(\mathbf{e}_m)\big), \quad m \in \{s, v, t\}, \tag{3}$$

$$\mathbf{e}_{\text{joint}} = \textstyle\sum_m \alpha_m \, \mathbf{e}_m. \tag{4}$$

Trực giác: mô thức nào hữu ích cho thực thể hiện tại thì nhận trọng số α_m lớn. Đây là "adaptive" trong tên mô hình. Lưu ý trọng số chỉ phụ thuộc embedding của *thực thể*, không phụ thuộc quan hệ đang hỏi: cùng một thực thể nhận cùng bộ α dù truy vấn là `locatedIn` hay `hasColor`.

Điểm lệch #1 (mã so với bài báo): Bài báo (phương trình 4 [1]) viết mỗi mô thức có một vector trọng số $\mathbf{w}_m$ *riêng*. Đọc mã (`ent_attn = Linear(2d,1)`) cho thấy chỉ có *một* vector $\mathbf{w}$ dùng chung cho cả ba mô thức, và ký hiệu $\oplus$ trong bài thực chất là tích vô hướng. Bản thân phương trình 4 [1] cũng viết chưa đúng kiểu: lấy exp của một tích từng phần tử cho ra vector chứ không ra trọng số vô hướng; phải đọc mã mới biết ý định là điểm vô hướng $\mathbf{w}^\top \tanh(\mathbf{e}_m)$. Nói cách khác, cơ chế attention model học được đơn giản hơn mô tả trong bài.

B. Huấn luyện đối kháng theo mô thức (MAT)

Đóng góp thứ hai. Một bộ sinh (generator) G, mạng truyền thẳng hai lớp LeakyReLU, nhận đầu vào là $[\mathbf{e}_s; \mathbf{z}]$ với $\mathbf{z} \sim \mathcal{N}(0,1)^{64}$, sinh ra các *mô thức giả* h^*, t^*. Ba biến thể bộ ba giả được tạo: (h^*, r, t), (h, r, t^*), (h^*, r, t^*). Mô hình chính đóng vai bộ phân biệt (discriminator) D:

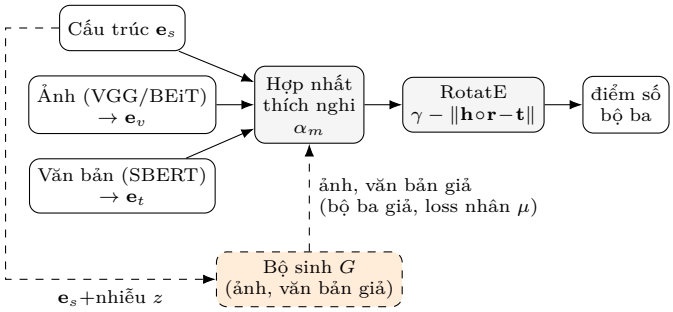
$$\mathcal{L}_D = \mathcal{L}_{\text{kgc}} + \mu \sum_{s \in S} \text{SigmoidLoss}(s), \tag{5}$$

$$\mathcal{L}_G = \sum_{s \in S} \text{SigmoidLoss}(s^+, s), \tag{6}$$

với S là ba bộ ba giả và μ (ký hiệu λ trong bài; từ đây báo cáo dùng μ) là hệ số cân bằng phần đối kháng. Cách ly gradient được xử lý bằng hai optimizer riêng cho D và G: dù $\mathcal{L}_G$ có lan gradient vào tham số D, chỉ `optimizer_g.step()` được gọi rồi `zero_grad()` ở bước D kế tiếp xóa sạch, nên không rò rỉ. Ý tưởng: G ép D học biểu diễn mô thức bền vững hơn trước nhiễu.

Đọc mã còn thấy ba chi tiết bài không nói rõ. Thực thể giả h^* thay *đồng thời* cả ảnh lẫn văn bản và giữ nguyên cấu trúc, nên bộ ba giả chỉ khác bộ ba thật ở hai mô thức bổ trợ. Mã chỉ sinh một nhóm ($L = 1$, tức ba bộ ba giả cho mỗi bộ ba dương), dù Hình 4 [1] của chính bài cho thấy $L = 8$ tốt nhất. Và khi $\mu = 0$, bộ sinh *vẫn* được cập nhật ở mỗi bước, chỉ là loss đối kháng của D bị nhân với 0 nên mô hình chính học y như AdaMF thuần: chi phí tính toán của MAT vẫn phải trả dù MAT không có tác dụng.

Điểm lệch #2 (ảnh hưởng lớn nhất tới tái lập): Cả ba script chính thức (`run_db15k/mkgw/mkgy.sh`) đều đặt `-mu=0`. Theo (5), $\mu = 0$ tắt hoàn toàn phần MAT. Vậy *chạy nguyên bản chỉ tái tạo AdaMF (ablation), không phải AdaMF-MAT*. Bài báo cho biết đã tìm $\mu \in \{0{,}1; 0{,}01; 0{,}001\}$ nhưng *không công bố giá trị được chọn*. Đây là rào cản tái lập lớn nhất, và là trọng tâm thực nghiệm của nhóm.



Hình 1. Luồng AdaMF-MAT. Ba mô thức được chiếu về cùng không gian, hợp nhất theo trọng số học được α_m, chấm điểm bằng RotatE. Nhánh nét đứt là pha đối kháng MAT: bộ sinh nhận embedding cấu trúc cộng nhiễu, tạo ảnh và văn bản giả; chúng đi qua cùng tầng hợp nhất để tạo bộ ba giả làm mẫu âm khó (hàm `get_fake_score` trong mã). Loss của nhánh này nhân μ, nên chỉ tác động khi $\mu > 0$.

Bảng II
MRR theo bài báo (trích Bảng 2 [1]): mô hình so sánh tốt nhất, AdaMF (không MAT) và AdaMF-MAT. Số in đậm: cao nhất trong hàng. Trên MKG-W và DB15K, AdaMF chưa có MAT còn thấp hơn mô hình so sánh tốt nhất.

Tập	So sánh tốt nhất	MRR	AdaMF	AdaMF-MAT
MKG-W	MMRNS	35,03	34,27	**35,85**
MKG-Y	VBKGC	37,04	38,06	**38,57**
DB15K	MMRNS	32,68	32,51	**35,14**

C. Minh họa luồng dữ liệu

Hình 1 tóm tắt luồng một bộ ba đi qua mô hình.

D. Kết quả bài báo công bố

Dữ liệu và chỉ số: Ba tập DB15K (từ DBpedia), MKG-W (Wikidata), MKG-Y (YAGO), thống kê ở Bảng III. Đánh giá bằng dự đoán liên kết cả đầu và đuôi, xếp hạng có lọc, đo MRR và Hit@$\{1, 3, 10\}$. *So sánh:* 19 baseline chia ba nhóm: 7 mô hình đơn mô thức (TransE đến GC-OTE), 7 mô hình đa mô thức (IKRL đến OTKGE) và 5 dòng lấy mẫu âm (KBGAN hai biến thể, MANS, MMRNS hai dòng). Một phần số baseline trích từ bài MMRNS, phần còn lại tác giả tự chạy lại. *Kết quả:* AdaMF-MAT đứng đầu cả ba tập (Bảng II), cải thiện trung bình so với 19 baseline (theo cách tính của bài) +6,0% MRR, +8,0% Hit@1, +5,5% Hit@3, +2,1% Hit@10. Ngoài kết quả chính, bài trả lời thêm ba câu hỏi: thiếu mô thức 20–80% trên DB15K thì MAT thêm khoảng 2 MRR ở mọi tỉ lệ (Hình 3 [1]); bỏ trọng số thích nghi, bỏ từng mô thức hay từng loại bộ ba giả đều làm giảm MRR (Bảng 3 [1]); và trọng số mô thức khác nhau theo quan hệ (Hình 5 [1]).

Đọc bảng này trước khi xem phần tái lập sẽ thấy vì sao MAT là trọng tâm kiểm chứng: theo bài báo, trên DB15K và MKG-W, AdaMF *chưa có* MAT còn thua mô hình so sánh tốt nhất, và chỉ nhờ MAT mới vượt. Toàn bộ vị trí dẫn đầu ở hai tập này dựa vào đóng góp của MAT.

Bảng III
Thống kê ba tập dữ liệu, đếm từ file thật. †: hai số này đảo so với Bảng 1 [1] (bài ghi kiểm định 9.902, kiểm thử 9.904).

			Số bộ ba		
Tập	Thực thể	Quan hệ	huấn luyện	kiểm định	kiểm thử
MKG-W	15.000	169	34.196	4.276	4.274
MKG-Y	15.000	28	21.310	2.665	2.663
DB15K	12.842	279	79.222	9.904†	9.902†

IV. Tái lập thực nghiệm

A. Thiết lập

Mã nguồn: repo chính thức `zjukg/AdaMF-MAT`. Đặc trưng ảnh/văn bản tiền huấn luyện (thiếu trong repo) được tải riêng, kiểm tra khớp chính xác số thực thể trong `entity2id.txt` (Bảng III). Chạy trên GPU NVIDIA Tesla T4 (16GB). Mã nguồn tái lập của nhóm và hướng dẫn chạy lại được công khai trên GitHub[1].

Bẫy tái lập đã gặp: (1) Phải *build lại* `Base.so` (loader C++ của OpenKE [6]) bằng `bash mmkgc/make.sh`; bản dựng sẵn dùng `-march=native` trên máy tác giả có thể ném *Illegal instruction* trên CPU khác kiến trúc. (2) Cờ `-img_dim` (mặc định 4096) khai trong `args.py` nhưng mô hình không dùng: số chiều đặc trưng ảnh được đọc thẳng từ file embedding (383 với MKG-W, MKG-Y; 4096 với DB15K), nên không cần truyền cờ này; dùng sẵn các script `run_*.sh` của tác giả. (3) Mã gốc *không có* cơ chế resume; DB15K một run 1000 epoch tốn khoảng 31 đến 35 giờ GPU (đo thật: 112–126 s/epoch trên T4), vượt giới hạn 12 giờ mỗi phiên GPU của nhóm. Nhóm tự thêm cờ `-resume` và cắt thành bốn phiên 250 epoch nối tiếp để chạy đủ (mục IV-E).

Siêu tham số (đọc từ script tác giả, MKG-W): `dim=200, margin=12, batch=1024, neg_num=128, lr=2e-5, epoch=1000`. Lưu ý `lr=2e-5` nằm *ngoài* lưới {1e-3, 1e-4, 1e-5} bài báo công bố, và DB15K dùng `dim=250` dù bài báo nói "set to 200".

B. Ghi nhận thực nghiệm (Weights & Biases)

Theo yêu cầu đề bài, mỗi thí nghiệm tái lập được ghi nhận công khai trên W&B [7]. Toàn bộ huấn luyện chạy trên GPU NVIDIA T4; nhóm lưu lại log huấn luyện gốc (loss theo epoch, kết quả từng fold, lệnh chạy đầy đủ). Các run W&B gồm hai loại, ghi rõ trong phần ghi chú của từng run. (1) Đợt chạy đầu: lúc chạy, môi trường huấn luyện chưa kết nối được W&B, nên run được tạo sau khi huấn luyện xong; kết quả cuối và *lịch sử theo epoch* (loss của bộ phân biệt và bộ sinh với AdaMF-MAT; loss, độ chính xác và macro-F1 trên test theo từng epoch và từng fold với MKG-FENN) được *nhập lại từ log gốc*, không phải ghi trực tiếp lúc huấn luyện; log gốc đã làm sạch đính kèm trong mục Files của run. Với DB15K, lịch sử nối bốn phiên 250 epoch theo epoch

[1] https://github.com/lqhung93/graphML-midterm-project

Bảng IV
TÁI LẬP TRÊN MKG-W. ΔMRR CỦA DÒNG BÀI BÁO SO VỚI ADAMF CỦA BÀI BÁO; CỦA NHÓM SO VỚI $\mu = 0$ CÙNG SEED (SEED 42 TÍNH TỪ SỐ CHƯA LÀM TRÒN 35,6786 VÀ 35,7347), VỚI 3 SEED LÀ TRUNG BÌNH CHÊNH LỆCH GHÉP CẶP; HIT@k CỦA 3 SEED LÀ TRUNG BÌNH. SỐ IN ĐẬM: CAO NHẤT TRONG CỘT GIỮA CÁC DÒNG MỘT LẦN CHẠY. ĐỘ LỆCH CHUẨN MRR GIỮA SEED KHOẢNG 0,06, NÊN CHÊNH LỆCH NHỎ HƠN MỨC NÀY KHÔNG PHÂN BIỆT ĐƯỢC VỚI NHIỄU.

Cấu hình	MRR	Hit@1	Hit@3	Hit@10	ΔMRR
Bài báo [1]					
AdaMF (μ=0)	34,27	27,21	37,86	47,21	
AdaMF-MAT	**35,85**	29,04	**39,01**	**48,42**	+1,58
Nhóm, seed 42					
μ=0	35,68	28,98	38,68	48,13	
μ=0,001	35,73	**29,11**	38,58	47,99	+0,06
μ=0,01	35,04	28,17	38,08	47,40	−0,64
μ=0,1	32,03	25,39	34,91	44,05	−3,65
Nhóm, trung bình 3 seed (42, 1, 2)					
μ=0	35,74±0,06	28,86	39,00	48,12	
μ=0,001	35,80±0,07	28,98	38,98	48,17	+0,06

toàn cục, trạng thái mô hình và optimizer được lưu ở cuối mỗi phiên và nạp lại ở phiên sau. (2) Đợt chạy bổ sung các seed còn thiếu: mã huấn luyện gọi `wandb.log` sau mỗi epoch, nên đường loss và chỉ số được ghi *trực tiếp* trong lúc huấn luyện. Thời gian chạy và thông tin máy trên W&B không phản ánh bước huấn luyện của đợt (1). Config của mỗi run ghi đủ siêu tham số thật; các run được xếp theo group (`adamf/main`, `adamf/mu`, `adamf/db15k`, `adamf/ablation`, `adamf/attention`, `mkgfenn/task1_main`, `mkgfenn/task2`, `mkgfenn/task3`, `mkgfenn/ablation`, `mkgfenn/sensitivity`). Xem Phụ lục A cho bảng ánh xạ đầy đủ run → liên kết; mỗi mục thực nghiệm dưới đây mở đầu bằng liên kết W&B của mục đó, đặt ở chú thích chân trang dưới dạng URL đầy đủ (bấm được trên bản PDF và vẫn đọc được trên bản in), giống cách hai bài báo gốc dẫn mã nguồn.

C. Kết quả chính: MKG-W, quét trọn lưới μ

Log và biểu đồ của phần này nằm trong báo cáo W&B công khai[2].

Bảng IV đối chiếu số nhóm đo được với số bài báo: lưới đầy đủ ở seed 42 và hai cấu hình chính lặp 3 seed (hai dòng cuối).

Bảng cho thấy mấy điều đáng chú ý. Trước hết, đường cơ sở của nhóm đã vượt đường cơ sở bài báo: AdaMF với $\mu = 0$ đạt 35,68 MRR, cao hơn số AdaMF mà bài báo công bố (34,27) là 1,41 và chỉ thấp hơn hàng AdaMF-MAT của họ (35,85) 0,17. Nói cách khác, chỉ riêng AdaMF chạy bằng chính script tác giả với MAT tắt đã gần chạm con số mà bài báo gán cho "AdaMF + MAT".

Trên chính con số đó, MAT không tái lập được đóng góp đã công bố. Quét trọn lưới $\mu \in \{0{,}1, 0{,}01, 0{,}001\}$ như bài báo nêu, giá trị tốt nhất ($\mu = 0{,}001$) chỉ thêm +0,06 MRR, cùng cỡ độ lệch chuẩn giữa seed (0,06), trong khi bài báo công bố +1,58; hai giá trị còn lại đều làm tệ đi. Kết quả nhạy với μ mà giá trị được chọn lại không được công bố: lệch một bậc ($\mu = 0{,}01$) đã mất 0,70 MRR so với $\mu = 0{,}001$, gần nửa mức đóng góp công bố; lệch hai bậc ($\mu = 0{,}1$) mất tới 3,71 MRR.

Để kết luận không chỉ dựa trên một lần chạy, nhóm lặp lại với ba seed (42, 1, 2). Trung bình ± độ lệch chuẩn của điểm MRR trên MKG-W là $35{,}74 \pm 0{,}06$ cho AdaMF ($\mu = 0$) và $35{,}80 \pm 0{,}07$ cho AdaMF-MAT ($\mu = 0{,}001$). Ghép cặp theo seed, chênh lệch MAT là +0,06, +0,01 và +0,11 MRR, trung bình $+0{,}06 \pm 0{,}05$ (độ lệch chuẩn của chênh lệch ghép cặp). Cả ba chênh lệch đều dương, nên công bằng mà nói MAT *có thể* có tác dụng dương rất nhỏ trên MKG-W; nhưng mức này thấp hơn mức +1,58 công bố khoảng 25 lần. Như vậy kết quả chưa tái hiện mức cải thiện được công bố; với ba seed, nhóm không thực hiện kiểm định để kết luận mức cải thiện khác 0 hay không.

Tập DB15K, nơi bài báo báo cáo MAT mạnh nhất (+2,63), được chạy riêng và cũng cho cùng kết luận (mục IV-E).

D. Mở rộng sang MKG-Y: cùng kết luận

Log và biểu đồ của phần này nằm trong báo cáo W&B công khai[3].

Nhóm quét trọn lưới μ trên tập thứ hai MKG-Y (seed 42, Bảng V). Kết quả lặp lại MKG-W: đường cơ sở $\mu = 0$ (39,10 MRR) vượt cả số AdaMF (38,06) lẫn AdaMF-MAT (38,57) mà bài báo công bố; MAT tốt nhất ($\mu = 0{,}01$) chỉ thêm +0,03 MRR (bài báo công bố +0,51), nhỏ hơn độ lệch chuẩn giữa seed đo trên MKG-W, còn $\mu = 0{,}1$ tụt −0,67. Hai cấu hình $\mu = 0$ và $\mu = 0{,}01$ được lặp thêm seed 1 và 2 (hai dòng cuối của Bảng V): trung bình 3 seed là $39{,}14 \pm 0{,}07$ và $39{,}13 \pm 0{,}06$. Ghép cặp theo seed, chênh lệch MAT là +0,03, −0,15 và +0,09, trung bình $-0{,}01 \pm 0{,}12$: trên MKG-Y, MAT gần như không có tác dụng và dấu thay đổi giữa các seed, trong khi bài báo công bố +0,51. Đường cơ sở 3 seed (39,14) vẫn cao hơn hàng AdaMF-MAT của bài báo (38,57). Hai tập dữ liệu độc lập cho cùng một kết luận: **mức đóng góp MAT công bố không tái hiện được**. Cả đường cơ sở lẫn cấu hình MAT đều chạy từ *cùng một script của tác giả*, chỉ khác giá trị μ (và seed), nên chênh lệch đến từ chính μ, không phải do nhóm đổi cấu hình.

E. DB15K: hai cấu hình đã thử chưa tái hiện mức công bố

Log và biểu đồ của phần này nằm trong báo cáo W&B công khai[4].

DB15K là tập bài báo công bố đóng góp MAT lớn nhất (+2,63 MRR). Mã gốc không có cơ chế resume mà một run 1000 epoch vượt giới hạn mỗi phiên GPU (Mục IV). Nhóm thêm cờ `-resume`/`-resume_out`/`-total_epoch`, cắt thành bốn phiên 250 epoch nối tiếp (chuyển trạng thái

[2] https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-k-t-qu-ch-nh-MKG-W-3-seed---VmlldzoxODE3OTk3Mw

[3] https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-l-i-h-s-MAT-tr-n-MKG-W-v-MKG-Y--VmlldzoxODE3OTk3NA

[4] https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-DB15K-1000-epoch--VmlldzoxODE3OTk3NQ

Bảng V
TÁI LẬP TRÊN MKG-Y; QUY ƯỚC NHƯ BẢNG IV. MỨC TĂNG DO MAT CỦA NHÓM KHÔNG VƯỢT 0,03 Ở MỌI CẤU HÌNH, SO VỚI +0,51 BÀI BÁO CÔNG BỐ.

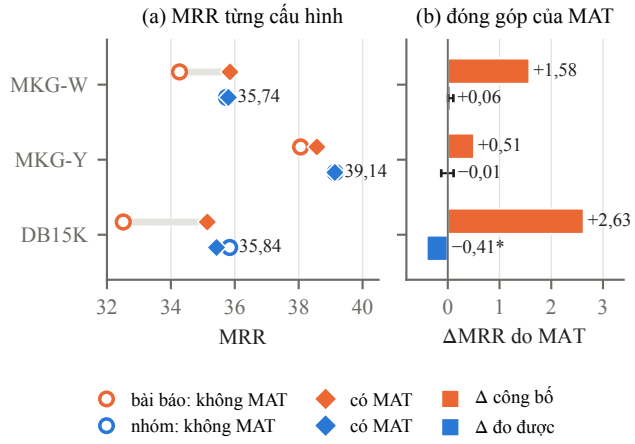
Cấu hình	MRR	Hit@1	Hit@3	Hit@10	ΔMRR
Bài báo [1]					
AdaMF (μ=0)	38,06	33,49	40,44	45,48	
AdaMF-MAT	38,57	34,34	40,59	45,76	+0,51
Nhóm, seed 42					
μ=0	39,10	34,59	41,23	**46,68**	
μ=0,001	39,10	34,59	41,19	46,60	−0,01
μ=0,01	**39,13**	**34,64**	**41,25**	46,58	+0,03
μ=0,1	38,43	33,85	40,67	45,96	−0,67
Nhóm, trung bình 3 seed (42, 1, 2)					
μ=0	39,14±0,07	34,72	41,05	46,66	
μ=0,01	39,13±0,06	34,65	41,11	46,61	−0,01

Bảng VI
TÁI LẬP TRÊN DB15K; QUY ƯỚC NHƯ BẢNG IV. ĐƯỜNG CƠ SỞ KHÔNG MAT CỦA NHÓM CAO HƠN CẢ HÀNG ADAMF-MAT CỦA BÀI BÁO, VÀ BẬT MAT LÀM MRR GIẢM.

Cấu hình	MRR	Hit@1	Hit@3	Hit@10	ΔMRR
Bài báo [1]					
AdaMF (μ=0)	32,51	21,31	39,67	51,68	
AdaMF-MAT	35,14	25,30	41,11	52,92	+2,63
Nhóm, seed 42, 1.000 epoch					
μ=0	**35,84**	**25,97**	**41,81**	**53,63**	
μ=0,01	35,43	25,34	41,50	53,38	−0,41

qua file resume), chạy đủ 1000 epoch cho cả $\mu = 0$ (không MAT) và $\mu = 0{,}01$ (MAT). Kết quả (Bảng VI) **lặp lại đúng mẫu của MKG-W/MKG-Y**: đường cơ sở không MAT của nhóm (35,84) vượt *cả* hàng AdaMF-MAT của bài báo (35,14), còn bật MAT ($\mu = 0{,}01$) lại *tụt* −0,41 thay vì +2,63 như công bố. Chênh giữa đường cơ sở bài báo (32,51) và của nhóm (35,84) là +3,33. Ít nhất ba khả năng có thể giải thích khoảng chênh của đường cơ sở: (i) mã và script phát hành là một phiên bản sau, khác cấu hình dùng cho bài báo (`lr=2e-5` nằm ngoài lưới công bố gợi ý điều này); (ii) khác phần cứng, phiên bản thư viện; (iii) hàng AdaMF trong bài được huấn luyện với cấu hình khác. Nhóm không phân biệt được ba khả năng này.

Phạm vi và giới hạn: Trên MKG-W và MKG-Y nhóm đã quét *trọn* lưới μ mà bài báo công bố, và đóng góp MAT cao nhất chỉ đạt +0,06. Riêng DB15K, do mỗi run cần bốn phiên GPU, nhóm mới thử được $\mu = 0{,}01$ với một seed. Bản thân bài báo cho thấy mức tăng của MAT khác nhau nhiều giữa các tập (+2,63, +1,58, +0,51), và DB15K còn khác về đặc trưng ảnh (VGG 4096 chiều) lẫn `dim=250`, nên kết quả MKG-W, MKG-Y không đủ để suy ra DB15K. Trên DB15K nhóm chỉ có một seed và một giá trị μ, nên đây là bằng chứng yếu nhất trong ba tập; nhóm *không* tuyên bố đã bác bỏ MAT trên DB15K. Nói gọn, **trong phạm vi các cấu hình nhóm đã thử, MAT chưa tái hiện được mức đóng góp đã công bố**; riêng DB15K, kết luận chỉ áp dụng cho $\mu = 0{,}01$. Hình 2 gom



Hình 2. Tóm tắt tái lập AdaMF-MAT trên ba tập. (a) MRR: hai hàng của bài báo (cam) và đường cơ sở không MAT của nhóm (xanh, thanh sai số là độ lệch chuẩn qua các seed). (b) Mức tăng MRR do MAT: bài báo công bố so với nhóm đo ở cấu hình MAT tốt nhất của nhóm ($\mu = 0{,}001$ trên MKG-W, 0,01 trên MKG-Y và DB15K), tính bằng chênh lệch ghép cặp theo seed; dấu * là một seed. Nhóm vẽ từ số đo trong Bảng IV đến VI.

Bảng VII
TRỌNG SỐ HỢP NHẤT TRUNG BÌNH TRÊN MKG-W (15.000 THỰC THỂ, CHECKPOINT $\mu = 0$; TRUNG BÌNH ± ĐỘ LỆCH CHUẨN QUA 3 SEED). ẢNH CHỈ NHẬN 1,7% TRỌNG SỐ, VÀ THỨ TỰ CẤU TRÚC > VĂN BẢN > ẢNH GIỮ NGUYÊN Ở CẢ 3 SEED.

Mô thức	Trọng số trung bình
cấu trúc	$0{,}5658 \pm 0{,}0014$
văn bản	$0{,}4173 \pm 0{,}0015$
ảnh	$0{,}0170 \pm 0{,}0004$

kết quả của ba tập vào một hình.

V. PHÂN TÍCH VÀ ĐỐI CHIẾU VỚI MÃ NGUỒN

A. Trọng số mô thức: hợp nhất thích nghi gán trọng số rất thấp cho ảnh

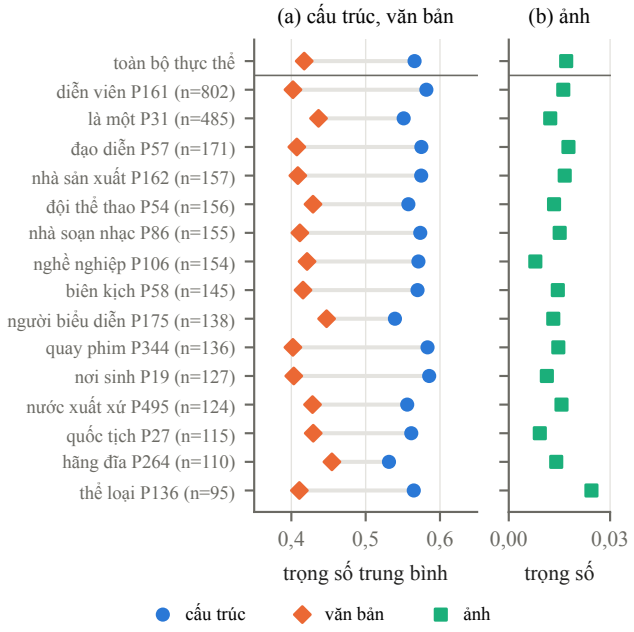
Log và biểu đồ của phần này nằm trong báo cáo W&B công khai[5].

Nhóm nạp checkpoint MKG-W ($\mu = 0$) của ba seed (42, 1, 2) và gọi thẳng hàm `get_attention` của model (không xấp xỉ lại). Bảng VII là trung bình trên toàn bộ 15000 thực thể; với checkpoint seed 42, nhóm còn tách theo 98 quan hệ trên tập test để so với Hình 5 [1].

Mô hình gán trọng số *rất thấp* cho mô thức ảnh (1,7%) trong khi văn bản được 41,7%, và thứ tự này giữ nguyên ở cả ba seed. Với một bài mang tên "giải phóng sức mạnh của mô thức mất cân bằng", đây là quan sát đáng nói: trên MKG-W, cơ chế thích nghi gần như *bỏ qua* ảnh chứ không cân bằng nó.

Hình 3 tách trọng số theo quan hệ (15 quan hệ có nhiều bộ ba test nhất, mã thuộc tính Wikidata). Các thanh gần như giống hệt nhau: cấu trúc 0,53 đến 0,59, ảnh không

[5] https://wandb.ai/K35/gml-adamf-mat/reports/AdaMF-MAT-ablation-m-th-c-v-tr-ng-s-attention--VmlldzoxODE3OTk3Ng



Hình 3. Trọng số hợp nhất trung bình theo quan hệ (MKG-W, checkpoint $\mu = 0$, seed 42; 15 quan hệ có nhiều bộ ba test nhất, ghi tên quan hệ Wikidata kèm mã, n là số bộ ba). Nhóm vẽ từ checkpoint đã huấn luyện.

quá 0,03. Điều này khớp với mã: trọng số là của *thực thể*, nên "trọng số theo quan hệ" chỉ là trung bình trên các thực thể xuất hiện trong quan hệ đó, khác nhau chủ yếu do thành phần thực thể chứ không do mô hình thích nghi theo ngữ cảnh. Trên cả 98 quan hệ có trong tập test, thứ tự $s > t > v$ đúng ở 97 quan hệ; quan hệ còn lại chỉ có 2 bộ ba test và ở đó văn bản nhỉnh hơn cấu trúc 0,0013.

Nhóm bỏ từng mô thức khỏi tầng hợp nhất rồi *huấn luyện lại từ đầu* (MKG-W, $\mu = 0$, Bảng VIII). Theo MRR và Hit@10, bỏ văn bản giảm nhiều nhất ($-1{,}15$ MRR); theo Hit@1, bỏ cấu trúc giảm nhiều nhất (27,34 so với 28,61 khi bỏ văn bản). Thứ hạng quan trọng vì vậy phụ thuộc chỉ số, và trọng số attention (cấu trúc 0,57 > văn bản 0,42) không trùng với mức quan trọng đo bằng ablation. Bỏ ảnh lại làm *tăng* MRR $+0{,}26$, lớn hơn mức kỳ vọng của một mô thức chỉ nhận trọng số 0,017; điều này gợi ý nhánh ảnh khả huấn luyện còn gây nhiễu cho quá trình tối ưu (chưa kiểm chứng). Bảng 3 [1] của bài báo làm ablation trên DB15K, còn nhóm làm trên MKG-W (vì chi phí DB15K), nên hai bảng không so trực tiếp được: bài báo thấy bỏ cấu trúc rớt mạnh nhất, gợi ý thứ tự này phụ thuộc tập dữ liệu. Nhóm cũng chưa chạy hai ablation khác của bài báo (hợp nhất thích nghi so với trung bình, và bỏ từng loại bộ ba tổng hợp của MAT). Mỗi cấu hình một seed; mức $+0{,}26$ và $-0{,}94$ lớn hơn nhiều độ lệch chuẩn giữa seed của MKG-W (0,06) nên hướng thay đổi đáng tin, còn độ lớn chính xác thì chưa.

Ở đây có một mâu thuẫn nội tại của bài báo. Mục 4.5 viết thứ tự quan trọng thường là $s > v > t$, nhưng chính

Bảng VIII
ABLATION MÔ THỨC (MKG-W, $\mu = 0$, SEED 42, HUẤN LUYỆN LẠI TỪ ĐẦU). Δ SO VỚI MÔ HÌNH ĐẦY ĐỦ. SỐ IN ĐẬM: CAO NHẤT TRONG CỘT. BỎ ẢNH CHO KẾT QUẢ CAO NHẤT Ở MỌI CHỈ SỐ; BỎ VĂN BẢN GIẢM MRR VÀ HIT@10 NHIỀU NHẤT, BỎ CẤU TRÚC GIẢM HIT@1 NHIỀU NHẤT. ĐỘ LỆCH CHUẨN MRR GIỮA SEED KHOẢNG 0,06.

Cấu hình	MRR	Hit@1	Hit@3	Hit@10	ΔMRR
Đầy đủ (3 mô thức)	35,68	28,98	38,68	48,13	
Bỏ cấu trúc	34,74	27,34	38,22	47,95	$-0{,}94$
Bỏ ảnh	**35,94**	**28,99**	**39,02**	**48,41**	$+0{,}26$
Bỏ văn bản	34,53	28,61	36,83	45,43	$-1{,}15$

Hình 5 [1] của họ (cả 7/7 quan hệ) lại cho $s > t > v$ với dải ảnh luôn mỏng nhất. Số nhóm đo trên MKG-W ($s > t > v$ ở 97/98 quan hệ, $s > v > t$ ở 0/98 quan hệ) *khớp với hình* của họ, chỉ lệch với câu văn. (Lưu ý: bài không nói Hình 5 [1] vẽ trên tập nào; nhóm đo trên MKG-W nên phát biểu đúng là "trên MKG-W thứ tự $s > v > t$ không đúng ở bất kỳ quan hệ nào".)

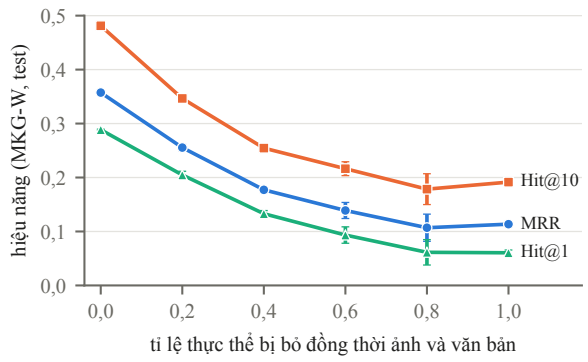
B. Độ bền khi thiếu mô thức (thí nghiệm tương tự Hình 3 [1])

Ba run W&B của phần này (3 seed) được ghi trực tiếp trong lúc chạy[6].

Hình 3 [1] của bài báo khảo sát độ bền khi một phần thực thể bị thiếu mô thức. Mã nguồn *không* kèm thí nghiệm này, nên nhóm tự viết: nạp checkpoint MKG-W ($\mu = 0$) của ba seed (42, 1, 2), rồi tại thời điểm kiểm thử, *zero-hóa* đặc trưng ảnh và văn bản cho một tỉ lệ p thực thể chọn ngẫu nhiên (mặt nạ dùng cùng seed với checkpoint), đo lại link prediction. Đây là can thiệp lúc suy luận, không huấn luyện lại. Hình 4 là kết quả. Tại $p = 0$, MRR trùng khớp đường cơ sở của từng seed (kiểm tra checkpoint nạp đúng). Thí nghiệm này khác bài báo ở ba điểm: tập MKG-W thay vì DB15K; chỉ có $\mu = 0$ nên không kiểm được phát biểu "MAT thêm khoảng 2 MRR"; và thiếu mô thức chỉ xảy ra lúc suy luận, nên đầu vào 0 nằm ngoài phân phối huấn luyện. Mức giảm đo được vì vậy là cận trên của độ phụ thuộc vào mô thức bổ trợ.

Đường cong này nói hai điều. Thứ nhất, hiệu năng tụt mạnh khi p tăng từ 0 đến 0,8 (MRR trung bình 0,357 $\rightarrow$ 0,107): mô hình phụ thuộc vào thông tin bổ trợ ngoài cấu trúc, nhưng thiết kế bỏ đồng thời ảnh và văn bản chưa cho phép tách đóng góp của từng mô thức (theo ablation ở trên, phần lớn mức giảm nhiều khả năng đến từ văn bản). Thứ hai, độ phân tán giữa seed tăng theo p (độ lệch chuẩn MRR 0,0006 ở $p = 0$ nhưng 0,025 ở $p = 0{,}8$), nên ở tỉ lệ thiếu cao một lần chạy không đủ tin cậy. Ví dụ cụ thể: với riêng seed 42, MRR ở $p = 1$ (0,111) cao hơn ở $p = 0{,}8$ (0,078), trông như mô hình "hồi phục" khi mọi thực thể cùng thiếu; nhưng seed 1 và 2 không lặp lại hiện tượng này (0,121 và 0,122 ở $p = 0{,}8$, so với 0,119 và 0,111

[6] https://wandb.ai/K35/gml-adamf-mat/runs/gvsjht9x, https://wandb.ai/K35/gml-adamf-mat/runs/4gyft23s, https://wandb.ai/K35/gml-adamf-mat/runs/90cvpets



Hình 4. Độ bền của AdaMF khi thiếu mô thức (MKG-W, checkpoint $\mu = 0$, 3 seed): trung bình ± độ lệch chuẩn của hiệu năng theo tỉ lệ thực thể bị bỏ đồng thời ảnh và văn bản.

ở $p = 1$), nên đó là nhiễu: từ $p = 0{,}8$ đến $p = 1$ đường cong chỉ đi ngang ($0{,}107 \pm 0{,}025$ so với $0{,}114 \pm 0{,}005$).

C. Các điểm không nhất quán bài báo ↔ mã nguồn

Tổng hợp từ đọc mã nguồn và kiểm chứng số (vị trí mã của các điểm chính ở Phụ lục B):

1) Script chính thức `mu=0` ⇒ chạy nguyên bản không ra AdaMF-MAT; μ được chọn không công bố. *(ảnh hưởng lớn tới tái lập)*
2) phương trình 4 [1] nói trọng số riêng từng mô thức; mã dùng *một* vector chung.
3) `dim`: bài báo "200", script DB15K dùng 250.
4) `lr=2e-5` nằm ngoài lưới bài báo công bố.
5) Bảng đặc trưng ảnh/văn bản là *khả huấn luyện* (`requires_grad =True`); riêng bảng ảnh DB15K chiếm 52,6M/71,4M tham số, không phải "∼10M".
6) Thí nghiệm modality-missing (Hình 3 [1], RQ2) *không có* trong mã phát hành: `-missing_rate`, `-visual` được khai trong `args.py` nhưng không nơi nào đọc. Muốn tái lập phải tự viết phần bỏ mô thức. *(ảnh hưởng lớn tới tái lập)*
7) Bảng 1 [1] ghi DB15K valid/test là 9902/9904, file thật đảo ngược 9904/9902, một chỗ chưa khớp nhỏ giữa bảng thống kê và file.
8) phương trình 8 [1] dường như lệch dấu so với định nghĩa $\mathcal{F}$ là khoảng cách ở phương trình 6 [1] (nhiều khả năng là lỗi in); mã đúng chiều.
9) phương trình 12–13 [1] cộng thứ hạng dự đoán đầu và đuôi mà thiếu hệ số 1/2, nên MRR và Hit@K theo công thức in có thể vượt 1; mã lấy trung bình hai chiều (log: đầu 0,186, đuôi 0,528, trung bình 0,357) nên số thực tế vẫn trong $[0, 1]$.
10) Cùng cấu hình AdaMF không MAT trên DB15K, Bảng 2 [1] ghi 32,51 MRR còn Bảng 3 [1] ghi 33,19.
11) Mục cài đặt và mã đặt $L = 1$, trong khi Hình 4 [1] cho $L = 8$ tốt nhất.
12) Câu văn Mục 4.5 nói thứ tự $s > v > t$, trái với chính Hình 5 [1] ($s > t > v$).
13) Bảng 2 [1] đặt chung số baseline trích từ bài MMRNS với số tác giả tự chạy lại, hai nguồn khác cấu hình.

Các phần khớp hoàn toàn: các phương trình RotatE, tập ba bộ ba giả, $K = 128$, $\beta = 2$, $\gamma = 12$, batch 1024, đánh giá filtered.

Tóm lại phần A, đóng góp thứ hai là MAT không tái lập được từ mã và dữ liệu công bố, kể cả khi nhóm quét lại trọn lưới μ trên MKG-W và MKG-Y; hai phương trình lõi (phương trình 4 [1], phương trình 8 [1]) lệch với mã của chính tác giả. Cái model thực sự học được là *một* vector attention dùng chung, không phải trọng số riêng từng mô thức như bài viết.

D. Đánh giá tổng hợp AdaMF-MAT

Điểm hiệu quả: Bài đặt đúng vấn đề: mỗi thực thể có lượng thông tin mô thức khác nhau, nên trọng số hợp nhất phải theo thực thể. Lời giải cho phần này rất rẻ, chỉ một vector attention và một softmax trên ba mô thức. Đường cơ sở AdaMF (RotatE, đặc trưng khả huấn luyện, hợp nhất thích nghi) chạy bằng chính script tác giả rất mạnh: vượt số AdaMF-MAT công bố trên MKG-Y và DB15K, tiến sát trên MKG-W; nhóm chưa tách được phần nào đến từ hợp nhất thích nghi vì chưa so với trung bình cộng. Ý tưởng sinh thẳng embedding mô thức giả bằng một mạng nhỏ cũng gọn, không cần học tăng cường như KBGAN, dù kết quả nhạy với μ.

Hạn chế và nguyên nhân: Phần đóng góp mới thứ hai, MAT, không đứng vững khi đường cơ sở được chạy đúng. Nhóm thấy ba lý do có thể giải thích (chưa kiểm định riêng từng cái). Một, đường cơ sở trong bài thấp hơn hẳn đường cơ sở chạy lại, có thể do mã phát hành khác cấu hình dùng cho bài (Mục IV-E). Hai, bộ sinh chỉ nhìn embedding cấu trúc cộng nhiễu, nên embedding giả mang rất ít thông tin về ảnh và văn bản thật; âm "khó" khi đó là khó giả tạo. Ba, kết quả nhạy với μ (lệch một bậc mất 0,7 MRR, lệch hai bậc mất 3,7) mà giá trị được chọn không được công bố. Ngoài ra, cái gọi là cân bằng mô thức trên thực tế là gán trọng số rất thấp cho ảnh, và phần mô tả trên giấy (phương trình 4 [1], phương trình 8 [1], phương trình 12–13 [1]) lệch với mã ở chỗ quan trọng.

Bài học rút ra: Một ablation kiểu "tắt thành phần X" chỉ chứng minh được X khi đường cơ sở được tinh chỉnh ngang bằng; nên báo cáo nhiều seed và công bố đúng cấu hình đã dùng. Công thức trên giấy có thể lệch mã ở đúng chỗ quyết định kết quả, nên phải đọc mã trước khi tin mô tả.

Hướng mở: Tác giả nêu hai hướng: kết hợp mô hình ngôn ngữ lớn với đồ thị tri thức đa mô thức, và dựng kịch bản thiếu mô thức sát thực tế hơn (chính tác giả nhận đây là giới hạn của bài). Nhóm thêm ba việc: cho bộ sinh dùng cả mô thức đang có (không chỉ cấu trúc) để embedding giả mang thông tin thật, cho attention phụ thuộc quan hệ đúng như bài mô tả, và đánh giá mọi so sánh bằng nhiều seed.

PHẦN B: MKG-FENN

Bảng IX là cùng khung bảy câu hỏi cho bài thứ hai.

Bảng IX
MKG-FENN THEO KHUNG PHÂN TÍCH CỦA NHÓM (CHI TIẾT Ở MỤC GHI TRONG NGOẶC).

Tóm tắt	Phân loại 65 loại sự kiện tương tác cho một cặp thuốc: bốn đồ thị tri thức, mỗi đồ thị một nhánh GNN kiểu KGNN, ghép đặc trưng hai thuốc rồi qua MLP, học end-to-end (Mục VII).
Khoảng trống nghiên cứu	Phương pháp dựa đặc trưng thuốc bỏ qua cấu trúc quan hệ; phương pháp đồ thị chỉ xét một phần quan hệ; mô hình lai trích và hợp nhất tách rời, không end-to-end (Mục VI).
Giải pháp	Lấy mẫu 6 láng giềng mỗi đồ thị, chấm điểm ngữ nghĩa thuốc–quan hệ để tổng hợp; ghép 8 vector của cặp thuốc vào MLP; cross-entropy, Adam (Mục VII).
Kết quả (bài báo)	572 thuốc, 37.264 cặp, 65 lớp; ACC, AUPR, AUC, F1, Precision, Recall; so 11 mô hình. Task 1 ACC 0,9409 (64 thắng, 2 hòa, 0 thua); Task 2 và 3 ACC 0,6805 và 0,4552 (31 thắng, 5 thua) (Mục VIII-B).
Điểm hiệu quả và hạn chế	Số chính tái lập được *theo giao thức của mã*. Bỏ một đồ thị không giảm Task 1; cold-start vẫn rất khó và chỉ dùng ba đồ thị; epoch chọn theo test cho F1 cao hơn epoch cuối 2,7–4,1 điểm (Mục VIII-C, VIII-H).
Bài học rút ra	Đọc cả mã đánh giá, không chỉ mã mô hình; "tái lập được" chỉ nghĩa là cùng giao thức (Mục VIII-I).
Hướng mở	Tác giả: thêm self-attention. Nhóm: tập validation riêng, G3 chỉ từ cặp huấn luyện, biểu diễn thuốc mới từ đặc trưng, nhiều lần chạy (Mục VIII-I).

VI. Bài toán dự đoán sự kiện tương tác thuốc

Tương tác thuốc (DDI) xảy ra khi dùng đồng thời hai thuốc làm thay đổi hiệu quả hoặc gây tác dụng phụ. MKG-FENN [2] giải bài toán *phân loại đa lớp*: cho một cặp thuốc (A, B), dự đoán *loại sự kiện* tương tác trong 65 loại (`event_num=65`), ví dụ "nguy cơ hoặc mức độ tác dụng phụ tăng lên". Dữ liệu nền gồm 572 thuốc (`n_drug=572`) từ DrugBank, cùng dòng dữ liệu với DDIMDL [5].

Cũng nên hình dung qua một ví dụ. Cho cặp thuốc `(Abemaciclib, Amiodarone)`, mỗi thuốc được tra đặc trưng từ bốn đồ thị tri thức (thực thể hóa học, cấu trúc con, DDI, thuộc tính phân tử) qua bốn nhánh KGNN, ghép thành tám vector rồi đưa qua MLP. Đầu ra là một trong 65 lớp sự kiện, ở đây là "nguy cơ hoặc mức độ tác dụng phụ tăng lên", đúng với nhãn trong `event.db` (dòng `Abemaciclib//Amiodarone//The risk or severity of adverse effects increase`).

Khoảng trống nghiên cứu: Bài chia các phương pháp trước thành ba nhóm, mỗi nhóm hụt một chỗ. Nhóm dựa trên đặc trưng thuốc (DeepDDI [21], MDF-SA-DDI [22], MDDI-SCL [23]) học tốt thuộc tính từng thuốc nhưng bỏ qua cấu trúc quan hệ bậc cao giữa thuốc, đích tác dụng, enzyme, chất vận chuyển. Nhóm dựa trên đồ thị (KGNN [4], SumGNN [24]) khai thác được cấu trúc đó nhưng chỉ xét một phần quan hệ. Nhóm mô hình lai (MDNN [26], MUFFIN [25]) kết hợp nhiều nguồn nhưng trích đặc trưng và hợp nhất ở hai bước tách rời, không end-to-end, nên đặc trưng không được tối ưu cho chính bài toán phân loại. MKG-FENN nhắm cả ba: dựng bốn đồ thị tri thức để phủ nhiều loại quan hệ, và học trích đặc trưng cùng hợp nhất *end-to-end* trong một mạng.

Bảng X
BỐN ĐỒ THỊ TRI THỨC CỦA MKG-FENN (ĐỌC TỪ `dataset1..4.txt` CỦA MÃ).

Đồ thị	Thuốc nối với	#cạnh	#quan hệ
G1	thực thể hóa học (đích tác dụng, enzyme, ...)	6.541	235
G2	cấu trúc con (một quan hệ "include")	70.350	1
G3	thuốc khác, quan hệ là loại sự kiện (DDI)	37.264	65
G4	thuộc tính phân tử (MolWt, MolLogP, ...)	11.440	13

VII. Kiến trúc MKG-FENN

A. Bốn đồ thị tri thức ("đa mô thức")

Bốn đồ thị (Bảng X), mỗi đồ thị mô tả thuốc theo một góc nhìn quan hệ khác nhau, định dạng `head//tail//relation`.

Nhãn sự kiện lấy từ `event.db` (SQLite), nhãn = cơ chế + hành động, sắp theo tần suất giảm dần thành 65 lớp.

B. Bốn nhánh GNN kiểu KGNN

Trái với cái tên "GNN" gợi ý message-passing sâu, mã thực thi là kiểu *lấy mẫu láng giềng + tổng hợp bằng attention* (giống KGNN [4]). Với mỗi đồ thị G_i và mỗi thuốc:

1) **Lấy mẫu.** Chọn ngẫu nhiên K láng giềng ($K = 6$ mặc định) từ G_i (`np.random.choice`, có lặp nếu thiếu), thu tail và quan hệ.
2) **Tính trọng số láng giềng.** Với embedding thuốc, quan hệ, thực thể (số chiều $d = 128$):

$$\mathbf{d}_{\text{rel}} = \mathbf{e}_{\text{drug}} \odot \mathbf{e}_{\text{rel}}, \tag{7}$$

$$\mathbf{s} = \text{ReLU}(\mathbf{d}_{\text{rel}} W_1 + b_1) W_2 + b_2, \tag{8}$$

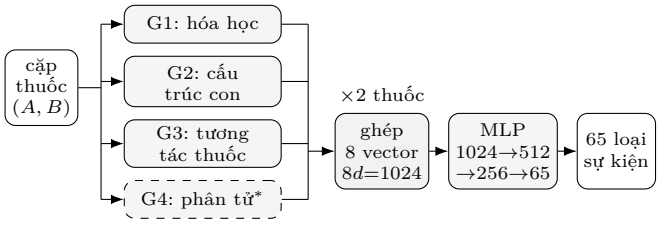
$$\boldsymbol{\alpha} = \text{softmax}\big(\textstyle\sum \mathbf{s}\big), \tag{9}$$

$$\mathbf{e}_{\text{agg}} = \boldsymbol{\alpha} \cdot \mathbf{e}_{\text{ent}}. \tag{10}$$

3) **Đặc trưng thuốc theo KG.** Ghép $[\mathbf{e}_{\text{agg}}; \mathbf{e}_{\text{drug}}]$ rồi qua Linear $(2d \to d)$+ReLU+BatchNorm, thu $\mathbf{f}_i$.

So với bài báo có hai khác biệt nhỏ nhưng có thật. phương trình 3 [2] của bài là tổng có trọng số không chuẩn hoá, còn mã chuẩn hoá trọng số láng giềng bằng softmax. Bias b_1, b_2 có kích thước $K \times d$, tức gắn với *vị trí* của láng giềng trong lượt lấy mẫu chứ không gắn với láng giềng cụ thể, trong khi các láng giềng được lấy mẫu lại ở mỗi lần forward.

Bẫy chi phí. Ma trận W_1, W_2 có kích thước $572 \times d \times d$, *riêng cho từng thuốc*. Mỗi nhánh vì thế cần $\approx 572 \times 128 \times$



Hình 5. MKG-FENN: mỗi thuốc của cặp đi qua bốn nhánh KGNN, mỗi nhánh trên một đồ thị, cho đặc trưng $\mathbf{f}_i^A, \mathbf{f}_i^B$ ($d = 128$); tám vector được ghép rồi qua MLP để phân loại 65 loại sự kiện. Mỗi nhánh KGNN lấy mẫu 6 láng giềng, tổng hợp có trọng số rồi qua Linear, ReLU, BatchNorm. *Ở cold-start (Task 2, 3), mã chỉ dùng ba nhánh G1 đến G3, bỏ G4.

$128 \times 2 \approx 18{,}7$ triệu tham số, bốn nhánh cộng lại cỡ 75 triệu chỉ cho phần KGNN. Đây là một chi phí tham số đáng kể mà cách mô tả kiến trúc trong bài báo không làm nổi bật, người đọc khó hình dung nếu chỉ nhìn sơ đồ.

Mỗi nhánh chỉ có một lớp tổng hợp ($l = 1$). Tác giả giải thích lựa chọn này bằng hiện tượng over-smoothing khi xếp nhiều lớp GNN (biểu diễn các nút bị kéo về giống nhau), nhưng không trình bày số liệu so sánh các giá trị l.

C. Tầng hợp nhất (FusionLayer)

Với mỗi cặp (A, B), ghép *tám* vector đặc trưng, $\{\mathbf{f}_1, \ldots, \mathbf{f}_4\}$ của A và của B, thành $8d = 1024$ chiều, rồi qua MLP $1024 \to 512 \to 256 \to 65$ (ReLU+BN+Dropout 0,3), xuất 65 lớp (Hình 5). Khi huấn luyện, mỗi cặp được nhân đôi thành (A, B) và (B, A) để đối xứng hóa.

VIII. Đánh giá và nhận xét

A. Ba kịch bản đánh giá

Mã cung cấp ba tác vụ với độ khó tăng dần:

- **Task 1**: chia ngẫu nhiên, StratifiedKFold 5-fold trên các cặp DDI. Dễ nhất: cả hai thuốc đều xuất hiện khi huấn luyện.
- **Task 2**: cold-start theo thuốc, kịch bản *một* thuốc trong cặp là mới (chưa xuất hiện khi huấn luyện). Khó hơn Task 1.
- **Task 3**: cold-start khó nhất, *cả hai* thuốc trong cặp đều mới.

Đọc mã cho thấy cold-start được làm như sau, điều bài báo không mô tả. 572 thuốc được chia thành năm nhóm; mỗi lượt một nhóm đóng vai thuốc mới, tập huấn luyện chỉ gồm cặp có cả hai thuốc cũ. Khi đánh giá, embedding của thuốc mới được *thay bằng embedding của thuốc cũ giống nó nhất* theo độ tương đồng Jaccard trên đặc trưng. Nói cách khác, mô hình không suy ra được biểu diễn cho thuốc mới mà mượn biểu diễn của một láng giềng gần nhất. Ngoài ra, mạng của Task 2 và Task 3 chỉ gồm GNN1 đến GNN3 và tầng hợp nhất $3 \cdot 2d$ chiều: cold-start thực tế dùng *ba* đồ thị, không phải bốn như bài viết. Chỉ số: ACC, AUPR, AUC, F1 (micro/macro), Precision, Recall, bộ 11 chỉ số toàn cục theo file supplementary.

Bảng XI
Kết quả Task 1 theo bài báo (trích Bảng 2 [2]): MKG-FENN và bốn mô hình có ACC cao nhất trong 11 mô hình so sánh. ACC, AUPR, AUC tính theo micro; F1, Precision, Recall theo macro. Số in đậm: cao nhất trong cột (AUC hòa giữa MKG-FENN và MDF-SA-DDI).

Mô hình	ACC	AUPR	AUC	F1	Precision	Recall
MKG-FENN	**0,9409**	**0,9786**	**0,9989**	**0,8958**	**0,9132**	**0,8876**
MDDI-SCL	0,9378	0,9782	0,9983	0,8755	0,8804	0,8767
MDF-SA-DDI	0,9301	0,9737	**0,9989**	0,8878	0,9085	0,8760
MDNN	0,9175	0,9668	0,9984	0,8301	0,8622	0,8202
DDIMDL	0,8852	0,9208	0,9976	0,7585	0,8471	0,7182

B. Kết quả chính (theo bài báo)

Trên kịch bản thuốc đã biết (Task 1, DrugBank v5.1.7, 572 thuốc, 65 sự kiện), bài báo báo cáo MKG-FENN không thua mô hình nào ở chỉ số nào (Bảng XI, số trích trực tiếp từ Bảng 2 [2] của bài báo): 64 thắng, 2 hòa, 0 thua trên 66 cặp chỉ số × mô hình, F-rank cao nhất 11,83 (F-rank là thứ hạng trung bình theo kiểm định Friedman, càng cao càng tốt). Hai trận hòa là AUC: 0,9989 bằng đúng MDF-SA-DDI và GNN. Bài còn đưa một ví dụ cụ thể: sự kiện số 62, một loại tương tác rất ít mẫu, chỉ MKG-FENN dự đoán đúng còn các mô hình so sánh đều bỏ sót; tác giả dùng ví dụ này để cho thấy đồ thị tri thức giúp ích nhất ở các lớp hiếm.

Một điều lộ rõ qua ba kịch bản là cold-start rất khó. Cùng một mô hình, ACC tụt mạnh theo độ khó: 0,9409 ở Task 1 (cả hai thuốc đã thấy), xuống 0,6805 ở Task 2 (một thuốc mới), rồi chỉ còn 0,4552 ở Task 3 (cả hai đều mới). Khoảng cách đó cho thấy phần lớn thành công nằm ở kịch bản dễ, còn dự đoán cho thuốc hoàn toàn mới vẫn là bài toán mở. Ở hai kịch bản cold-start, bài báo cũng không thắng toàn diện: mỗi kịch bản 31 thắng, 5 thua trên 36 cặp (6 chỉ số × 6 mô hình); chẳng hạn ACC Task 3 của MDDI-SCL (0,4589) cao hơn MKG-FENN (0,4552), còn F1 và Precision Task 2 thua MDF-SA-DDI. Còn các giá trị $p = 0{,}0156$ của kiểm định Wilcoxon cần đọc thận trọng: đó là giá trị nhỏ nhất có thể khi so 6 cặp ($1/2^6$, một phía), và 6 cặp ở đây là 6 chỉ số tương quan của *cùng một* lần chạy, không phải nhiều lần chạy độc lập.

Về giao thức, ba yếu tố bài báo coi là quan trọng nhất (phân tích độ nhạy): số láng giềng lấy mẫu tốt nhất = 6, "trọng số mất mát phân loại" (CLW) tốt nhất = 10^{-8}, số chiều embedding = 128. Trong mã, CLW thực chất là `weight_decay` của Adam, tức hệ số điều chuẩn ℓ_2, không phải trọng số của một thành phần loss. Supplementary quét số láng giềng trong $\{4, 5, 6, 7\}$ và cho biết mọi thí nghiệm chạy trên CPU (Windows, i5, 8GB RAM), khớp với việc mã gốc không hỗ trợ GPU. Bài dùng 120 epoch, lr = 0,01, batch 1024: các giá trị này khớp mã (dù nằm ngoài tập `choices` khai trong argparse, nên đây là lỗi khai báo chứ không phải lệch bài báo↔mã).

C. Nhóm tái lập (GPU T4, 3 seed)

Log và biểu đồ của phần này nằm trong báo cáo W&B công khai[7]. Mã nguồn tái lập nằm cùng repo GitHub ở Mục IV.

Nhóm GPU-hóa mã (thêm `.to(device)`, mã gốc chỉ chạy CPU) và chạy lại Task 1 (120 epoch, 5-fold) với **3 seed** (0, 1, 2), mỗi lần ∼1 giờ. Trung bình ± độ lệch chuẩn **khớp bài báo ở mọi chỉ số, số bài báo nằm trong khoảng ± độ lệch chuẩn** (Bảng XII), nên Task 1 của MKG-FENN *tái lập được*. Đây là tương phản rõ với Phần A: cùng một cách kiểm chứng cho hai kết luận trái ngược, tùy công trình.

Nhóm dùng một tiêu chí tái lập thực dụng xuyên suốt báo cáo: xem là *nhất quán với bài báo* khi con số công bố nằm trong một độ lệch chuẩn mẫu của nhóm qua ba lần chạy độc lập. Đây là quy tắc so khớp thực dụng, không phải khoảng tin cậy hay kiểm định giả thuyết, nên phát biểu đúng là "không phân biệt được với số công bố ở mức nhiễu ba seed", chứ không khẳng định bằng chứng mạnh hơn thế. Theo tiêu chí này, số bài báo nằm trong khoảng ở cả 6 chỉ số. Ba run tương ứng trên W&B ở chú thích[8].

D. Nhóm tái lập cold-start (Task 2 và Task 3)

Log và biểu đồ của phần này nằm trong báo cáo W&B công khai[9].

Nhóm chạy lại luôn kịch bản khó Task 2 (cold-start, một thuốc mới) với **3 seed** độc lập (GPU T4, seed 1, 2, 3, mỗi lần ∼1 giờ; 100 epoch theo mặc định của mã Task 2, trong khi bài báo dùng 120 epoch). Nhóm giữ mặc định của mã Task 2 để tái lập đúng điều kiện mã công bố; chỉnh lên 120 epoch sẽ là một giao thức khác. ACC trung bình 0,6772±0,0039, **số bài báo** 0,6805 **nằm trong khoảng ± độ lệch chuẩn**, Recall cũng vậy; nhưng AUPR, AUC, F1 và Precision của nhóm thấp hơn số bài báo khoảng 1 đến 3 độ lệch chuẩn (Bảng XII), có thể một phần do ít epoch hơn. Lưu ý mã Task 2 chỉ tính AUPR/AUC theo micro và F1/Precision/Recall theo macro (các ô còn lại gán cứng bằng 0, nhóm không ghi các ô này lên W&B), nên AUPR mà bài báo báo ở Bảng 3/4 [2] thực chất là AUPR micro; cách trung bình macro trên nhiều lớp sự kiện hiếm khiến F1/Precision/Recall thấp hơn hẳn Task 1, phản ánh đúng độ khó của dự đoán cho thuốc chưa từng thấy.

Ba run tương ứng trên W&B ở chú thích[10].

Nhóm chạy tiếp **Task 3** (cold-start, *cả hai* thuốc mới: khó nhất), cũng 3 seed (seed 1, 2, 3, 120 epoch; Bảng XII). ACC trung bình 0,4598 ± 0,0175, **số bài báo** 0,4552 **nằm trong ± độ lệch chuẩn**, cùng AUPR, AUC, F1 và Recall; riêng Precision thấp hơn bài báo (0,2618 so với 0,2754). Chỉ số F1/Precision/Recall (macro) tụt sâu (∼0,21–0,26) đúng như kỳ vọng khi mọi cặp thuốc đều chưa từng thấy. Độ lệch chuẩn ACC 0,0175 rộng tới mức cả MKG-FENN (0,4552) lẫn MDDI-SCL (0,4589) đều nằm trong khoảng; tái lập không đủ để xác nhận thứ hạng giữa hai mô hình. Nhóm phải tự GPU-hóa mã Task 3 (giống Task 2) vì bản gốc chỉ chạy CPU.

Ba run tương ứng trên W&B ở chú thích[11]. Tóm lại, ACC của cả hai kịch bản cold-start tái lập được (số bài báo nằm trong 1 độ lệch chuẩn), còn một số chỉ số macro thấp hơn nhẹ; các con số chính của MKG-FENN tái lập được *dưới cùng giao thức của mã*. Đây là nhận định về *tính tái lập*, không phải về giá trị kiến trúc: ablation 3 seed dưới đây chưa quan sát được mức giảm khi bỏ một đồ thị mà Bảng 5 [2] báo cáo.

E. Ablation KG: bỏ một đồ thị không làm giảm ACC Task 1

Log và biểu đồ của phần này nằm trong báo cáo W&B công khai[12].

Nhóm bỏ từng đồ thị khỏi FusionLayer (Task 1, 3 seed: 0, 1, 2, Bảng XIII) bằng cách gán embedding của nhánh đó bằng 0 suốt quá trình huấn luyện và kiểm thử (huấn luyện lại từ đầu). Kích thước đầu vào MLP giữ nguyên, nhưng các trọng số nhận đầu vào 0 không còn tác dụng, nên tương đương bỏ hẳn nhánh. **Qua 3 seed, bỏ bất kỳ đồ thị nào, kể cả đồ thị tương tác thuốc (G3), đều không làm giảm ACC**: trung bình của bốn cấu hình là 0,9397 đến 0,9409, chênh lệch ghép cặp theo seed so với mô hình đầy đủ chỉ từ −0,0006 đến +0,0006, nhỏ hơn độ lệch chuẩn giữa seed của mô hình đầy đủ (0,0012). Macro-F1 cũng không giảm. Điều này lệch với Bảng 5 [2] của bài báo: ở đó cả bốn tổ hợp ba đồ thị chỉ đạt 0,9344 đến 0,9355, thấp hơn đủ bốn đồ thị 0,54 đến 0,65 điểm, tức khoảng năm lần độ lệch chuẩn giữa seed của nhóm, xem Hình 6b. Bài báo không nói cách bỏ kênh, nên khác biệt có thể một phần do cách cài đặt; nhóm không kết luận các đồ thị là thừa, chỉ ghi nhận rằng với cách bỏ kênh này, mức giảm ở Bảng 5 [2] không tái hiện được. *Phạm vi:* nhóm chỉ chạy bốn cấu hình bỏ một đồ thị trong 15 tổ hợp của Bảng 5 [2], chỉ trên Task 1; cold-start (Task 2/3) có thể khác.

F. Phân tích độ nhạy siêu tham số (Task 1, 3 seed)

Nhóm quét lại hai siêu tham số bài báo nhấn mạnh: số láng giềng lấy mẫu (`neighbor_sample_size`) và số chiều embedding (`embedding_num`), mỗi giá trị 3 seed (0, 1, 2) trên GPU T4 (Bảng XIV). Với `neighbor_sample_size`, ACC trung bình gần như trùng nhau (0,9402 đến 0,9403 cho cả bốn giá trị 4, 6, 10, 16), nên trong khoảng này

[7] https://wandb.ai/K35/gml-adamf-mat/reports/MKG-FENN-Task-1-3-seed---VmlldzoxODE3OTk3Nw

[8] https://wandb.ai/K35/gml-adamf-mat/runs/r628r0ym, https://wandb.ai/K35/gml-adamf-mat/runs/o01zi2q5, https://wandb.ai/K35/gml-adamf-mat/runs/3x8y37ey

[9] https://wandb.ai/K35/gml-adamf-mat/reports/MKG-FENN-cold-start-Task-2-v-Task-3--VmlldzoxODE3OTk3OA

[10] https://wandb.ai/K35/gml-adamf-mat/runs/7xspj9x8, https://wandb.ai/K35/gml-adamf-mat/runs/hloy7vw3, https://wandb.ai/K35/gml-adamf-mat/runs/86w5hqon

[11] https://wandb.ai/K35/gml-adamf-mat/runs/6n59pyvb, https://wandb.ai/K35/gml-adamf-mat/runs/swvbyr32, https://wandb.ai/K35/gml-adamf-mat/runs/wqablhkc

[12] https://wandb.ai/K35/gml-adamf-mat/reports/MKG-FENN-ablation-th-v-nh-y-si-u-tham-s---VmlldzoxODE3OTk3OQ

Bảng XII
MKG-FENN: nhóm tái lập ba kịch bản so với bài báo (trích Bảng 2, 3, 4 [2]). Nhóm: trung bình ± độ lệch chuẩn qua 3 seed (Task 1: seed 0, 1, 2; Task 2, 3: seed 1, 2, 3; Task 2 chạy 100 epoch theo mặc định của mã). ACC, AUPR, AUC tính theo micro; F1, Precision, Recall theo macro. †: số bài báo nằm ngoài khoảng trung bình ± 1 độ lệch chuẩn của nhóm. Task 1 khớp cả sáu chỉ số; ở cold-start, ACC khớp còn một số chỉ số macro thấp hơn.

	Task 1: thuốc đã biết		Task 2: một thuốc mới		Task 3: hai thuốc mới	
Chỉ số	Nhóm	Bài báo	Nhóm	Bài báo	Nhóm	Bài báo
ACC	0,9403 ±0,0012	0,9409	0,6772 ±0,0039	0,6805	0,4598 ±0,0175	0,4552
AUPR	0,9782 ±0,0007	0,9786	0,7010 ±0,0015	0,7049†	0,4140 ±0,0165	0,4162
AUC	0,9990 ±0,0001	0,9989	0,9663 ±0,0008	0,9673†	0,9153 ±0,0014	0,9149
F1	0,8932 ±0,0041	0,8958	0,5294 ±0,0045	0,5394†	0,2162 ±0,0076	0,2186
Precision	0,9202 ±0,0090	0,9132	0,5862 ±0,0075	0,6063†	0,2618 ±0,0092	0,2754†
Recall	0,8813 ±0,0055	0,8876	0,5045 ±0,0071	0,5106	0,2097 ±0,0107	0,2131

Bảng XIII
MKG-FENN, ablation đồ thị (Task 1, 3 seed): bỏ một đồ thị không làm giảm ACC. Số của nhóm là trung bình qua seed 0, 1, 2 (ACC kèm độ lệch chuẩn); Δ là chênh lệch ACC ghép cặp theo seed so với mô hình đầy đủ (điểm phần trăm). Cột cuối là ACC của tổ hợp ba đồ thị tương ứng trong Bảng 5 [2] (P1 đến P4 ứng với G1 đến G4). Không in đậm vì mọi chênh lệch của nhóm đều nhỏ hơn độ lệch chuẩn giữa seed.

Bỏ	ACC	ΔACC	F1 (macro)	Bài báo
không (đủ 4)	0,9403±0,0012		0,8932	0,9409
G1 hóa học	0,9397±0,0012	−0,06	0,8926	0,9351
G2 cấu trúc con	0,9405±0,0005	+0,02	0,8957	0,9349
G3 tương tác thuốc	0,9406±0,0014	+0,03	0,8981	0,9355
G4 phân tử	0,9409±0,0011	+0,06	0,9000	0,9344

Bảng XIV
MKG-FENN, độ nhạy siêu tham số (Task 1, 3 seed): chỉ số chiều embedding nhỏ làm giảm rõ ACC. Trung bình ± độ lệch chuẩn qua seed 0, 1, 2; dòng "gốc" là mô hình đầy đủ; Δ là chênh lệch ACC ghép cặp theo seed so với cấu hình gốc (điểm phần trăm). In đậm: chênh lệch vượt rõ độ lệch chuẩn giữa seed.

Siêu tham số	Giá trị	ACC	ΔACC	F1 (macro)
`neighbor_`	4	0,9403±0,0013	−0,00	0,8935±0,0021
`sample_size`	6 (gốc)	0,9403±0,0012		0,8932±0,0041
	10	0,9402±0,0008	−0,00	0,8957±0,0020
	16	0,9403±0,0012	+0,00	0,8968±0,0025
`embedding_num`	32	0,9233±0,0012	**−1,70**	0,8523±0,0059
	64	0,9369±0,0015	−0,34	0,8837±0,0033
	128 (gốc)	0,9403±0,0012		0,8932±0,0041
	256	0,9418±0,0006	+0,15	0,8975±0,0023

số láng giềng không ảnh hưởng tới ACC và nhóm không xác nhận được "số láng giềng = 6 tốt nhất" như bài báo; macro-F1 nhích lên theo số láng giềng nhưng vẫn trong độ lệch chuẩn. Với `embedding_num`, 32 chiều kém rõ (−1,70 điểm ACC và −4,1 điểm macro-F1, gấp khoảng mười bốn lần độ lệch chuẩn giữa seed), 64 chiều kém nhẹ (−0,34 điểm), còn 256 chiều chỉ hơn 128 chiều +0,15 điểm, chưa vượt nhiễu, trong khi tốn gấp 2,5 lần thời gian. Như vậy, trong hai tham số, chỉ dung lượng mô hình có tác động đo được, và 128 chiều đã gần mức bão hòa. Nhóm chưa quét tham số thứ ba bài báo nêu là trọng số loss phân loại (CLW).

Mười tám run này nằm cùng báo cáo W&B với ablation đồ thị ở mục trên.

G. Bẫy tái lập của MKG-FENN

Ngoài số tái lập trên, đọc mã còn lộ vài điểm cần lưu nếu ai muốn tái lập:

1) Repo chỉ có `event.rar`, mã lại cần `event.db`; phải giải nén trước, nếu không `sqlite3.connect` sẽ lỗi.
2) GNN3 hardcode `num_embeddings=67` cho bảng quan hệ trong khi dataset3 chỉ có 65 quan hệ (đệm +2), cần kiểm off-by-two là cố ý hay lỗi.
3) Mặc định `lr=1e-2` và `epoches=120` nằm *ngoài* tập `choices` khai trong argparse, giá trị thật khác lưới liệt kê.
4) Lấy mẫu láng giềng ngẫu nhiên *mỗi lần forward* ⇒ kết quả có phương sai giữa các lần chạy dù đã cố định seed. Nên báo cáo trung bình nhiều lần thay vì một con số.

H. Giao thức đánh giá: chọn epoch theo tập test

Đọc kỹ hàm huấn luyện còn lộ một vấn đề phương pháp quan trọng hơn mọi điểm lệch ở trên. Trong mỗi fold, mã đánh giá trên *tập test* sau từng epoch và giữ lại đầu ra của epoch có macro-F1 trên test cao nhất (vị trí mã ở Phụ lục B); không có tập validation riêng. Số báo cáo vì thế là số tốt nhất trên test qua toàn bộ quá trình huấn luyện. Vì log huấn luyện ghi chỉ số test sau mỗi epoch, nhóm so được epoch được chọn với epoch cuối cùng mà không cần chạy thêm GPU (Bảng XV).

Vì tiêu chí chọn là macro-F1, chênh lệch rõ nhất ở F1: so với epoch cuối, epoch được chọn cho macro-F1 cao hơn 0,027 ở Task 1, 0,029 ở Task 2 và 0,041 ở Task 3 (tức 2,7 đến 4,1 điểm phần trăm). ACC Task 1 ở epoch cuối còn cao hơn epoch được chọn (0,9420 so với 0,9403), nhưng ACC Task 3 tăng 0,017, gần bằng một độ lệch chuẩn giữa các lần chạy. Về hướng, chọn epoch có macro-F1 trên test cao nhất chỉ có thể làm macro-F1 báo cáo *tăng hoặc bằng* so với một quy trình chọn không nhìn test, nên số macro-F1 công bố là cận trên lạc quan (với ACC thì không chắc,

Bảng XV
MKG-FENN: chỉ số ở epoch được chọn theo macro-F1 trên tập test so với epoch cuối (Δ = chọn − cuối; nhóm tính từ log, trung bình theo fold rồi trung bình 3 seed, nên hơi khác số gộp ở Bảng XII). Chọn epoch theo test nâng macro-F1 thêm 2,7 đến 4,1 điểm phần trăm; ACC không tăng đều.

	ACC			F1 (macro)		
Task	chọn	cuối	Δ	chọn	cuối	Δ
Task 1	0,9403	0,9420	−0,0017	0,8859	0,8585	**+0,0274**
Task 2	0,6781	0,6741	+0,0040	0,5432	0,5142	**+0,0290**
Task 3	0,4670	0,4505	+0,0165	0,2365	0,1959	**+0,0406**

như Task 1 cho thấy); mọi so sánh với mô hình khác dùng cùng giao thức cần đọc dưới trần đó. Chênh lệch này cho thấy kết quả nhạy với cách chọn epoch, nhưng chưa định lượng trực tiếp độ chệch so với quy trình chọn mô hình bằng validation độc lập; cần đánh giá lại bằng validation độc lập để xác định mức ảnh hưởng. Vì vậy "tái lập được" ở các mục trên nghĩa là tái lập *cùng giao thức*.

Một rủi ro khác nằm ở đồ thị G3: nó được dựng từ *toàn bộ* 37.264 sự kiện DDI, gồm cả các cặp thuộc fold test, với quan hệ chính là loại sự kiện, tức nhãn cần dự đoán. Khi lấy mẫu láng giềng, mô hình có thể gặp đúng cặp test cùng nhãn của nó. Xác suất này thấp (6 láng giềng trên khoảng 130 láng giềng trung bình mỗi thuốc), và thí nghiệm bỏ G3 không làm giảm ACC Task 1 (Bảng XIII: bỏ G3 cho $0{,}9406 \pm 0{,}0014$ qua 3 seed, không thấp hơn mô hình đầy đủ), nên nhóm cho rằng rò rỉ qua G3 không phải nguồn chính của số Task 1. Ở cold-start, G3 vẫn chứa các cặp test của thuốc mới cùng nhãn của chúng, nên rò rỉ có thể ảnh hưởng mạnh hơn Task 1; số Task 2, 3 cần đọc với giả định này, nhóm chưa loại trừ được.

I. Đánh giá tổng hợp MKG-FENN

Điểm hiệu quả: Bài nhìn thuốc qua nhiều đồ thị tri thức cùng lúc và học hợp nhất end-to-end, một thiết kế dễ hiểu, chạy được cả trên CPU, và số Task 1 tái lập sát bài báo ở cả 6 chỉ số. Việc đánh giá ba mức độ khó, từ thuốc đã biết tới cả hai thuốc mới, cho thấy trung thực rằng cold-start vẫn rất khó.

Hạn chế và nguyên nhân: Lợi ích của bốn đồ thị chưa được chứng minh thuyết phục: bỏ một đồ thị không làm giảm Task 1, và cold-start, nơi thông tin ngoài nhãn cần nhất, lại chỉ dùng ba đồ thị. Thiết kế W_1, W_2 riêng cho từng thuốc tốn khoảng 75 triệu tham số cho 572 thuốc và không áp được cho thuốc mới, nên cold-start phải mượn embedding của thuốc giống nhất. Giao thức chọn epoch theo test và kiểm định Wilcoxon trên 6 chỉ số làm các khẳng định vượt trội yếu hơn vẻ ngoài của bảng kết quả.

Bài học rút ra: Muốn tin một con số, phải đọc cả mã đánh giá chứ không chỉ mã mô hình; "tái lập được" chỉ có nghĩa là ra cùng số dưới cùng giao thức. Ablation nên làm cả ở cold-start, nơi thông tin ngoài nhãn thực sự cần.

Hướng mở: Tác giả chỉ nêu một hướng: thêm cơ chế self-attention. Nhóm đề xuất: tách tập validation, dựng G3 chỉ từ cặp huấn luyện, biểu diễn thuốc mới từ đặc trưng của nó thay vì tra bảng, và báo cáo nhiều lần chạy kèm kiểm định giữa các lần chạy.

Bảng XVI
Đối chiếu hai công trình.

	AdaMF-MAT	MKG-FENN
Tác vụ	hoàn thiện đồ thị (dự đoán liên kết)	phân loại 65 loại sự kiện tương tác thuốc
Hợp nhất cái gì	các *mô thức* của một thực thể (cấu trúc, ảnh, văn bản)	các *loại quan hệ* của một thuốc (4 đồ thị)
Xương sống	RotatE, thêm pha đối kháng MAT	4 nhánh KGNN, MLP
Nhóm chạy lại	MKG-W, MKG-Y (3 seed), DB15K	Task 1/2/3 (3 seed), ablation, độ nhạy
Số chính	đường cơ sở tái lập; mức tăng của MAT *chưa* tái hiện	Task 1 tái lập ở 6 chỉ số; cold-start khớp ACC, một số chỉ số macro thấp hơn nhẹ
Phát hiện chính	script đặt `mu=0`; phương trình 4 [1], phương trình 8 [1] lệch mã; ảnh nhận trọng số rất thấp	chọn epoch theo test; cold-start dùng 3 đồ thị; qua 3 seed, bỏ 1 đồ thị không giảm ACC

IX. So sánh hai công trình

Bảng XVI đặt cạnh hai cách "hợp nhất trên đồ thị".

X. Bài học khi tái lập

Đặt hai công trình cạnh nhau, nhóm rút ra mấy bài học áp dụng được cho việc đọc bất kỳ bài báo học máy nào.

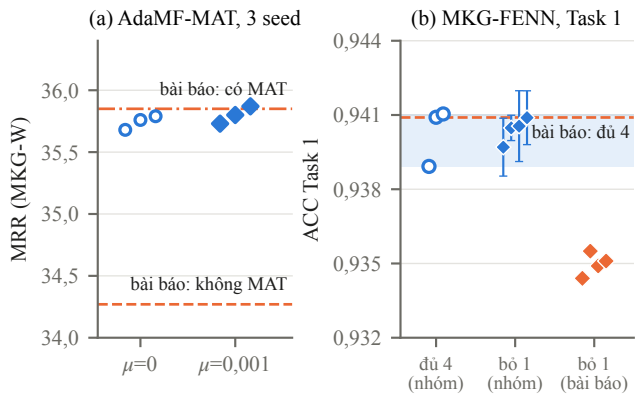
Nhiễu giữa các lần chạy phải được đo trước khi so sánh: Hình 6 đặt độ phân tán giữa seed của nhóm cạnh chênh lệch mà bài báo dùng để kết luận. Ở AdaMF-MAT, khoảng cách giữa $\mu = 0$ và $\mu = 0{,}001$ cùng cỡ độ phân tán giữa seed, trong khi bài báo công bố +1,58. Ở MKG-FENN, trung bình 3 seed của bốn cấu hình bỏ một đồ thị đều nằm trong dải ba seed của mô hình đầy đủ. Một con số một lần chạy không đủ để nói thành phần nào có ích.

Đường cơ sở quyết định đóng góp: Đóng góp của MAT gần như không còn khi AdaMF được chạy bằng chính script của tác giả, và đường cơ sở chạy lại cao hơn hẳn số bài báo ghi cho nó. Muốn chứng minh một thành phần, đường cơ sở phải được tinh chỉnh ngang bằng.

Đọc mã đánh giá, không chỉ mã mô hình: Vấn đề phương pháp đáng lưu ý nhất nhóm tìm thấy ở MKG-FENN không nằm trong kiến trúc mà trong vòng huấn luyện: chọn epoch theo tập test. Ở AdaMF-MAT, cấu hình quan trọng nhất (μ) nằm trong script chạy chứ không trong bài.

Công thức trên giấy có thể khác mã: Cả hai bài đều có công thức lệch mã ở chỗ then chốt (trọng số attention, dấu của trọng số âm, chuẩn hoá láng giềng, số đồ thị ở cold-start). Khi hai nguồn mâu thuẫn, mã là thứ thực sự tạo ra số.

Ghi lại quá trình ngay từ đầu: Với đợt chạy đầu, nhóm phải dựng lại sổ thí nghiệm sau khi đã huấn luyện xong vì



Hình 6. Độ phân tán giữa các lần chạy của nhóm so với chênh lệch mà bài báo báo cáo. (a) AdaMF-MAT trên MKG-W: 3 seed cho $\mu = 0$ và $\mu = 0{,}001$; nét đứt là số bài báo. (b) MKG-FENN Task 1: dải 3 seed của mô hình đầy đủ (vùng tô), bốn cấu hình bỏ một đồ thị của nhóm (trung bình ± độ lệch chuẩn qua 3 seed), và bốn cấu hình tương ứng trong Bảng 5 [2] của bài báo (hình thoi). Nhóm vẽ từ số đo trong báo cáo.

lúc chạy chưa kết nối được công cụ ghi log (đợt bổ sung đã ghi trực tiếp); giữ nguyên log gốc là điều giúp nhóm vẫn kiểm chứng được mọi con số, kể cả mức chênh ở Bảng XV.

XI. Kết luận

Hai công trình cùng theo đuổi hợp nhất có học trên đồ thị tri thức đa mô thức nhưng cho hai bài học trái ngược về tính tái lập.

Với AdaMF-MAT, nhóm quét toàn bộ lưới hệ số MAT được công bố trên MKG-W (thêm ba seed) và MKG-Y; trên DB15K, nhóm đánh giá hai cấu hình $\mu = 0$ và $\mu = 0{,}01$ trong 1.000 epoch bằng cơ chế resume tự thêm. Trong phạm vi các cấu hình đã thử, MAT chưa tái hiện được mức cải thiện công bố: ở MKG-W chỉ $+0{,}06 \pm 0{,}05$ MRR và ở MKG-Y $-0{,}01 \pm 0{,}12$ (chênh lệch ghép cặp qua 3 seed) so với +1,58 và +0,51, và tại DB15K nơi bài báo công bố MAT mạnh nhất (+2,63) thì cấu hình đã thử lại *giảm* 0,41. Đường cơ sở không MAT của nhóm vượt kết quả AdaMF-MAT công bố trên MKG-Y và DB15K, đồng thời tiến sát kết quả công bố trên MKG-W. Trên MKG-W, phần hợp nhất thích nghi gán trọng số rất thấp cho ảnh; thí nghiệm thiếu mô thức tương tự Hình 3 [1] (ba seed) cho thấy hiệu năng giảm mạnh khi thiếu đồng thời ảnh và văn bản lúc suy luận.

Với MKG-FENN, cả ba kịch bản (biết thuốc và hai mức cold-start) đều tái lập trong một độ lệch chuẩn *theo đúng giao thức của mã*. Nhưng giao thức đó chọn epoch theo macro-F1 trên tập test, và epoch được chọn cho F1 cao hơn epoch cuối 2,7 đến 4,1 điểm phần trăm (chưa phải độ chệch so với chọn bằng validation); ablation của nhóm không tái lập được mức giảm khi bỏ một đồ thị mà Bảng 5 [2] báo cáo; cold-start thực tế chỉ dùng ba đồ thị và mượn embedding của thuốc giống nhất; và kiến trúc tuy gọn về ý tưởng lại nặng về tham số (W_1, W_2 riêng từng thuốc). Cả hai trường hợp củng cố nguyên tắc làm việc của nhóm: không tin một phát biểu trong bài báo cho đến khi chỉ được dòng mã thực thi nó. Hướng tiếp theo nhóm muốn làm là chạy ablation mô thức của AdaMF-MAT với nhiều seed, đánh giá lại MKG-FENN với tập validation riêng, và thử bộ sinh có điều kiện mạnh hơn cho MAT.

Phụ lục A
Ánh xạ thực nghiệm → liên kết Weights & Biases

Toàn bộ **67 run** đều ở chế độ xem công khai trong project https://wandb.ai/K35/gml-adamf-mat. Danh sách đầy đủ liên kết từng thí nghiệm:

AdaMF-MAT, MKG-W (nhiều seed, ablation mô thức, trọng số attention):

- μ=0 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/qxown5dl
- μ=0 seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/k354evcb
- μ=0 seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/9af2psno
- μ=0,001 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/f9cf4x8f
- μ=0,001 seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/zj1788o7
- μ=0,001 seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/1lhysap5
- μ=0,01 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/sc9m0keu
- μ=0,1 seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/5w6rka9v
- ablation bỏ cấu trúc: https://wandb.ai/K35/gml-adamf-mat/runs/rilzsiqn
- ablation bỏ ảnh: https://wandb.ai/K35/gml-adamf-mat/runs/cvgimw2j
- ablation bỏ văn bản: https://wandb.ai/K35/gml-adamf-mat/runs/77e9wlty
- trọng số mô thức (Figure 5) seed 42: https://wandb.ai/K35/gml-adamf-mat/runs/cwnekvuv
- trọng số mô thức seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/tj6p6n72
- trọng số mô thức seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/pfk5ok3p
- thiếu mô thức (Figure 3), seed 42, bản đầu: https://wandb.ai/K35/gml-adamf-mat/runs/ipdub3kv
- thiếu mô thức, 3 seed (ghi trực tiếp): seed 42 https://wandb.ai/K35/gml-adamf-mat/runs/gvsjht9x, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/4gyft23s, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/90cvpets

AdaMF-MAT, MKG-Y (lưới μ):

- μ=0: https://wandb.ai/K35/gml-adamf-mat/runs/64amdvgx
- μ=0,001: https://wandb.ai/K35/gml-adamf-mat/runs/2d6cplzt

- μ=0,01: https://wandb.ai/K35/gml-adamf-mat/runs/85xezi64
- μ=0 seed 1 (ghi trực tiếp): https://wandb.ai/K35/gml-adamf-mat/runs/o7pt24ag
- μ=0 seed 2 (ghi trực tiếp): https://wandb.ai/K35/gml-adamf-mat/runs/7lndwu9d
- μ=0,01 seed 1 (ghi trực tiếp): https://wandb.ai/K35/gml-adamf-mat/runs/j61vgq3c
- μ=0,01 seed 2 (ghi trực tiếp): https://wandb.ai/K35/gml-adamf-mat/runs/ilt04pow
- μ=0,1: https://wandb.ai/K35/gml-adamf-mat/runs/5nkdeeui

AdaMF-MAT, DB15K (1000 epoch):

- μ=0 (không MAT): https://wandb.ai/K35/gml-adamf-mat/runs/cjefby6u
- μ=0,01 (MAT): https://wandb.ai/K35/gml-adamf-mat/runs/86ki6d7x

MKG-FENN, Task 1 (3 seed, ablation đồ thị, độ nhạy siêu tham số):

- seed 0: https://wandb.ai/K35/gml-adamf-mat/runs/r628r0ym
- seed 1: https://wandb.ai/K35/gml-adamf-mat/runs/o01zi2q5
- seed 2: https://wandb.ai/K35/gml-adamf-mat/runs/3x8y37ey
- bỏ G1: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/yqu4qtwp, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/vki4rwx7, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/b7d7rxqk
- bỏ G2: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/yq0wyql5, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/ffw530vc, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/z09t36mg
- bỏ G3: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/kcoyhcsv, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/x1oeez5o, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/wt1r71mu
- bỏ G4: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/krxvj5yv, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/164nu2s0, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/t1rgmxpd
- ns=4: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/pnzncirw, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/2ofdt0hc, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/25l3hgi2
- ns=10: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/9xktau7r, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/ld3yjf3o, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/4y5wp589
- ns=16: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/mjdlfme6, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/7dd4fbpf, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/fujgo9za
- emb=32: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/nzdee5fy, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/8ysokinf, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/tklgf05q
- emb=64: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/2k7kzbbr, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/p0b63pmn, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/wvti0keu
- emb=256: seed 0 https://wandb.ai/K35/gml-adamf-mat/runs/wc3qt7ke, seed 1 https://wandb.ai/K35/gml-adamf-mat/runs/zouypuk8, seed 2 https://wandb.ai/K35/gml-adamf-mat/runs/lahxou78

MKG-FENN, cold-start (Task 2 và Task 3):

- Task 2 lần 1: https://wandb.ai/K35/gml-adamf-mat/runs/7xspj9x8
- Task 2 lần 2: https://wandb.ai/K35/gml-adamf-mat/runs/hloy7vw3
- Task 2 lần 3: https://wandb.ai/K35/gml-adamf-mat/runs/86w5hqon
- Task 3 lần 1: https://wandb.ai/K35/gml-adamf-mat/runs/6n59pyvb
- Task 3 lần 2: https://wandb.ai/K35/gml-adamf-mat/runs/swvbyr32
- Task 3 lần 3: https://wandb.ai/K35/gml-adamf-mat/runs/wqablhkc

Phụ lục B
Vị trí mã của các phát hiện chính

Đường dẫn tính từ gốc repo GitHub của nhóm; tên hàm thay cho số dòng để không lệch khi mã đổi.

Tài liệu tham khảo

[1] Y. Zhang, Z. Chen, L. Liang, H. Chen, and W. Zhang, "Unleashing the Power of Imbalanced Modality Information for Multi-modal Knowledge Graph Completion," in *Proc. LREC-COLING*, 2024. arXiv:2402.15444.

[2] D. Wu, W. Sun, Y. He, Z. Chen, and X. Luo, "MKG-FENN: A Multimodal Knowledge Graph Fused End-to-end Neural Network for Accurate Drug–Drug Interaction Prediction," in *Proc. AAAI*, vol. 38, no. 9, 2024, pp. 10216–10224. DOI: 10.1609/aaai.v38i9.28887.

[3] Z. Sun, Z.-H. Deng, J.-Y. Nie, and J. Tang, "RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space," in *Proc. ICLR*, 2019.

[4] X. Lin, Z. Quan, Z.-J. Wang, T. Ma, and X. Zeng, "KGNN: Knowledge Graph Neural Network for Drug–Drug Interaction Prediction," in *Proc. IJCAI*, 2020, pp. 2739–2745.

[5] Y. Deng, X. Xu, Y. Qiu, J. Xia, W. Zhang, and S. Liu, "A multimodal deep learning framework for predicting drug–drug interaction events," *Bioinformatics*, vol. 36, no. 15, pp. 4316–4322, 2020.

[6] X. Han et al., "OpenKE: An Open Toolkit for Knowledge Embedding," in *Proc. EMNLP (System Demonstrations)*, 2018, pp. 139–144.

[7] L. Biewald, "Experiment Tracking with Weights and Biases," 2020. [Online]. Available: https://www.wandb.com/

[8] A. Bordes, N. Usunier, A. Garcia-Duran, J. Weston, and O. Yakhnenko, "Translating Embeddings for Modeling Multi-relational Data," in *Proc. NeurIPS*, 2013.

[9] B. Yang, W. Yih, X. He, J. Gao, and L. Deng, "Embedding Entities and Relations for Learning and Inference in Knowledge Bases," in *Proc. ICLR*, 2015.

[10] T. Trouillon, C. R. Dance, É. Gaussier, J. Welbl, S. Riedel, and G. Bouchard, "Knowledge Graph Completion via Complex Tensor Factorization," *J. Mach. Learn. Res.*, 2017.

Bảng XVII
PHÁT HIỆN → VỊ TRÍ MÃ.

Phát hiện	Vị trí
phương trình 4 [1]: một vector attention chung	AdaMF-MAT/mmkgc/module/model/AdvMixRotatE.py, `self.ent_attn` trong `__init__` và hàm `get_joint_embeddings`
Bảng đặc trưng ảnh, văn bản khả huấn luyện	AdvMixRotatE.py, `requires_grad_(True)` trên `img_embeddings`, `text_embeddings`
Script chính thức đặt `mu=0`	`AdaMF-MAT/scripts/run_*.sh`
`-missing_rate`, `-visual` không được dùng	`AdaMF-MAT/args.py` khai báo, không file nào đọc
Ablation mô thức của nhóm	`get_joint_embeddings`, nhánh `ablation` (`no_s`, `no_v`, `no_t`)
MKG-FENN chọn epoch theo F1 trên test	MKG-FENN/code/MKG-FENN-task1.py, hàm `train`: `if test_score == max(test_list)` giữ `max_test_output`
G3 dựng từ toàn bộ 37.264 sự kiện	MKG-FENN-task1.py, khối `__main__`: `read_dataset(dict1, 3)` trên bảng `extraction` của `event.db`
CLW thực chất là `weight_decay`	MKG-FENN-task1.py, hàm `train`: `torch.optim.Adam(..., weight_decay=args.weigh_decay)`
W_1, W_2 riêng từng thuốc	MKG-FENN/code/modeltask1.py: `nn.Parameter(torch.randn(size=(572, d, d)))`
Cold-start mượn embedding thuốc giống nhất	MKG-FENN/code/MKG-FENN-task2.py, hàm `Jaccard`
Ablation đồ thị của nhóm	`modeltask1.py`, cờ `drop_kg`: gán `zeros_like` cho nhánh bị bỏ

[11] R. Xie, Z. Liu, H. Luan, and M. Sun, "Image-embodied Knowledge Representation Learning," in *Proc. IJCAI*, 2017.

[12] H. Mousselly Sergieh, T. Botschen, I. Gurevych, and S. Roth, "A Multimodal Translation-based Approach for Knowledge Graph Representation Learning," in *Proc. *SEM*, 2018.

[13] M. Wang, S. Wang, H. Yang, Z. Zhang, X. Chen, and G. Qi, "Is Visual Context Really Helpful for Knowledge Graph? A Representation Learning Perspective," in *Proc. ACM MM*, 2021.

[14] Z. Cao, Q. Xu, Z. Yang, Y. He, X. Cao, and Q. Huang, "OTKGE: Multi-modal Knowledge Graph Embeddings via Optimal Transport," in *Proc. NeurIPS*, 2022.

[15] L. Cai and W. Y. Wang, "KBGAN: Adversarial Learning for Knowledge Graph Embeddings," in *Proc. NAACL*, 2018.

[16] D. Xu, T. Xu, S. Wu, J. Zhou, and E. Chen, "Relation-enhanced Negative Sampling for Multimodal Knowledge Graph Completion," in *Proc. ACM MM*, 2022.

[17] Y. Zhang, M. Chen, and W. Zhang, "Modality-aware Negative Sampling for Multi-modal Knowledge Graph Embedding," *CoRR*, 2023.

[18] K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-scale Image Recognition," in *Proc. ICLR*, 2015.

[19] H. Bao, L. Dong, S. Piao, and F. Wei, "BEiT: BERT Pre-training of Image Transformers," in *Proc. ICLR*, 2022.

[20] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in *Proc. EMNLP*, 2019.

[21] J. Y. Ryu, H. U. Kim, and S. Y. Lee, "Deep Learning Improves Prediction of Drug–Drug and Drug–Food Interactions," *Proc. Natl. Acad. Sci.*, vol. 115, no. 18, pp. E4304–E4311, 2018.

[22] S. Lin *et al.*, "MDF-SA-DDI: Predicting Drug–Drug Interaction Events Based on Multi-source Drug Fusion, Multi-source Feature Fusion and Transformer Self-attention Mechanism," *Briefings in Bioinformatics*, vol. 23, no. 1, bbab421, 2022.

[23] S. Lin, W. Chen, G. Chen, S. Zhou, D.-Q. Wei, and Y. Xiong, "MDDI-SCL: Predicting Multi-type Drug–Drug Interactions via Supervised Contrastive Learning," *J. Cheminformatics*, vol. 14, no. 1, 2022.

[24] Y. Yu, K. Huang, C. Zhang, L. M. Glass, J. Sun, and C. Xiao, "SumGNN: Multi-typed Drug Interaction Prediction via Efficient Knowledge Graph Summarization," *Bioinformatics*, vol. 37, no. 18, pp. 2988–2995, 2021.

[25] Y. Chen, T. Ma, X. Yang, J. Wang, B. Song, and X. Zeng, "MUFFIN: Multi-scale Feature Fusion for Drug–Drug Interaction Prediction," *Bioinformatics*, vol. 37, no. 17, pp. 2651–2658, 2021.

[26] T. Lyu, J. Gao, L. Tian, Z. Li, P. Zhang, and J. Zhang, "MDNN: A Multimodal Deep Neural Network for Predicting Drug–Drug Interaction Events," in *Proc. IJCAI*, 2021, pp. 3536–3542.